

I1

¡Bienvenidos a la Interrogación 1!

Indicaciones:

- Esta prueba está pensada en poder realizarse en un plazo máximo de 2.5 horas, pero se les dará un tiempo de 72 horas para que puedan gestionar su tiempo correctamente. Son libres de usar el tiempo a su gusto y tienen intentos ilimitados. No se aceptan entregas atrasadas bajo ningún concepto, dado el generoso plazo que tienen para organizarse.
- Sea preciso y completo en sus respuestas, esto facilita la transmisión de ideas desde ustedes al equipo docente. Cada respuesta tiene un límite de 250 palabras o 1600 caracteres a menos que se especifique lo contrario. Preguntas que sobrepasen este límite no serán evaluadas
- La prueba es estrictamente individual. No copie. La idea es tratar de evaluar los conceptos y que aprenda los principales contenidos del curso para su propio beneficio, no se auto-engañe. El uso de LLMs está limitado a preguntas de conceptos básicos del curso en caso de que tengan dudas, no para copiar/pegar el caso (lo cual se nota y mucho cuando se hace). Pueden revisar apuntes, sitios web y libros para realizar esta prueba, citando siempre su uso al pie de cada pregunta. Inclusiones sin citas serán consideradas como copia.
- Para las preguntas de modelación les pedimos que entreguen diagramas entendibles y ordenados, digitales. Para eso apóyense de distintas páginas que les pueden ayudar a generar sus diagramas como diagrams.net . Entregas escaneadas desde el papel tienen 0 puntos y no serán revisadas
- Para sus consultas se habilitó el canal [#interrogaciones](#)  en el Slack del curso. Se tendrá un horario de consulta en donde pueden publicar dudas entre los dos primeros días de prueba (primeras 48 horas), y los profesores las irán respondiendo durante el periodo que tendrán disponible la interrogación. Cualquier duda realizada pasadas las primeras 48 horas no será respondida.
- Este curso se adscribe a la política de integridad académica del DCC, que se encuentra en el programa del curso. Esperamos que respeten la política de integridad académica, y los exámenes serán comparados con diversos métodos para revisar casos de copia.

1.a) (4 pts) Dados los siguientes atributos de calidad: Seguridad, Disponibilidad, Escalabilidad, Confiabilidad, Performance. Arme 2 pares que más les acomoden entre estos NFR e indique, para cada par, un caso donde se pueda ver que uno se ve beneficiado por usar el otro, y otro caso donde uno se vea afectado negativamente porque se está usando el otro.

250 máx. (límite de palabras)

Caso I

Actualmente, los Large Language Models o LLMs predominan en masa en la oferta de AIs comerciales. Estas AIs tienen grandes capacidades para responder a diversos *prompts*, los cuales dictan la información u operaciones que requiere un usuario para satisfacer sus necesidades de datos. Incluso más, varios de estos LLMs proporcionan funcionalidad adicional en forma de tratamiento de información de otros tipos de fuentes (multi-modal) donde se pueden ingresar PDFs, fotos, archivos de datos para dar respuestas de forma aún más fácil a sus usuarios.

Sin embargo, la cantidad no necesariamente implica calidad. No todos estos modelos responden igual y todos tienden a cometer cierto grado de error en su funcionamiento, ya sea proporcionando respuestas incompletas o derechamente erradas (alucinaciones). Estos errores degradan la experiencia del usuario y marcan diferencias sustanciales entre *vendors*.

Para abordar esta situación, LegitQA le encarga generar un sistema capaz de hacer benchmarks semi-automatizados de todos los modelos disponibles de AI en el mercado, con el fin de mostrar los resultados en una plataforma abierta y eficiente. Para hacer este benchmarking, cada *vendor* de AI debe registrar su LLM mediante un identificador de AI (arbitrario), un método de integración (REST o Model Context Protocol) con un schema compatible, una cuenta de servicio y una *API key*. Este registro es en una plataforma sencilla, por invitación mediante correo electrónico.

Al ingresar su AI, cada *vendor* podrá suscribirse a diversos *challenges*, que son métodos de evaluación del output producido por estas AIs en base a criterios específicos. Estos challenges están clasificados en dos tipos

- Fully-automated: Estos *challenges* están formados por programas previamente proporcionados de forma completamente automática, los cuales pueden enviar prompts de texto y/o multimedia (voz, audio, video) usando la API proporcionada por el *vendor* y que esperan una determinada respuesta, la cual puede ser evaluada por un pequeño programa validador o alguna AI de referencia propiedad de LegitQA. Estos programas se van actualizando con el

tiempo en repositorios Git de origen a medida que van mejorando los *challenges*, puesto que las respuestas mejoran con el tiempo (e.g. Livebench)

- Crowd-dependant: A diferencia de los anteriores, estos *challenges* están basados en la votación del público especializado. Se toman ciertos usuarios y se les presenta la respuesta de los modelos frente a diversos escenarios preestablecidos, para posteriormente pedirles un rating de la calidad de la respuesta. Estos escenarios preestablecidos son programas de tamaño pequeño que hacen prompts preguardados específicos y reservan el resultado para enseñarlo a los usuarios en una UI donde pueden acceder (e.g. LLM arena). Al igual que los challenges fully-automated, también van recibiendo actualizaciones con el tiempo

Debe diseñar un sistema que administre estos *challenges* a las AIs registradas con el fin de mostrar un Leaderboard público con los puntajes obtenidos por todos estos challenges, además de reportar los resultados a los *vendors* que registraron sus LLMs. Se espera que el sistema sea capaz de tener los benchmarks lo antes posible para evitar competidores en este mismo ámbito y que use

Puntos importantes para su conveniencia

- La AI de referencia es un módulo black-box de capacidad limitada con dos interfaces, una de entrada que recibe un resultado de un test dado y una de salida que da un score (1 a 100)
- Los blobs usados por los challenges (y cualquier otro blob que generen) pueden guardarse en un object storage para fácil acceso (al estilo S3). Para evitar congestión de red a causa de blobs, son buckets públicos y se recomienda que su sistema solo pase referencias
- Solo cuenta con un subset de infraestructura básica de la nube (VMs, S3, VPC, API gateway, CDN, ECR, ECS, Fargate o sus equivalentes en GCP o Azure) además de un IdP a elección.
- Recuerde que un diagrama de componentes es distinto a un diagrama de despliegue
- Los *vendors* ofrecen llamadas a sus APIs bajo cierto rate limiting, variable por cada proveedor

2

Ensayo 2 puntos

2.a) Los challenges podrían ser decenas o cientos. ¿Como podría promocionarse la mantenibilidad y escalabilidad rápida de un sistema con tantos programas? Proponga 3 tácticas diferentes y apropiadas. Justifique su uso

250 máx. (límite de palabras)

3

Ensayo 2 puntos


2.b) Propón un sistema de rate limiting y quota enforcement por vendor, para no explotar por los aires los rate limits. Investigue el concepto de Circuit breaker y vea cómo aplicarlo

250 máx. (límite de palabras)

4

Ensayo 4 puntos

2.c) Indique (mínimo 3, pero pueden ser más) atributos de calidad vistos en clases que Ud. considere son fundamentales en este problema. Enumérelos en orden de prioridad y justifique brevemente




250 máx. (límite de palabras)

5

Ensayo 5 puntos

2.d) Indique (mínimo 2, pero pueden ser más) los estilos arquitectónicos vistos en clases que va a emplear para solucionar el problema. Indique qué aspecto del problema ataca cada estilo (responsabilidad).



250 máx. (límite de palabras)

6

Carga del archivo 12 puntos

Este tipo de pregunta no puede imprimirse

2.e) Confeccione un diagrama de componentes UML indicando los componentes arquitectónicos y sus relaciones, además de sus estilos especificados previamente, tal que reflejen una solución al problema planteado. Añada tanto detalle como haga falta para que quede claro cómo soluciona el problema planteado. Incluya anotaciones explicando funcionamiento y supuestos, así como nombres de interfaces



Arrastrar y soltar aquí o [Examinar](#)

Se permite un máximo de 1 archivo(s) ¡.pdf,.jpeg,.png,.jpg solamente!

7

Ensayo 4 puntos

2.f) Identifique 2 trade-off originados de la solución de su diagrama. Comente como las solucionaría y las implicancias de estas soluciones. No se corregirán aquellas que apunten al formato de cómo se diagramó o si faltó explotar algún componente

250 máx. (límite de palabras)

Caso II

Dado el creciente aumento de la industria de los videojuegos para consolas, muchos desarrolladores jóvenes quieren involucrarse en este sin tener mayor experiencia, generándoles problemas al momento de optimizar sus juegos para las distintas plataformas usando, muchas veces, computadores y máquinas que no son las mejores.