



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

Clase 29: Simulacro Interrogación: LMEval

Francisco Gazitúa Requena (fco_gazitua_requena@uc.cl)

IIC2113 Diseño Detallado de Software

18 de Noviembre, 2025

Interrogación 2025-1

Un modelo de lenguaje es un tipo de IA que permite predecir la palabra más probable que le sigue a una frase.

Un modelo de lenguaje es un tipo de IA que permite predecir la palabra más probable que le sigue a una frase. Por ejemplo:

- “No he comido y tengo” → “hambre”
- “Raichu es un” → “pokémon”

Un modelo de lenguaje es un tipo de IA que permite predecir la palabra más probable que le sigue a una frase. Por ejemplo:


- “No he comido y tengo” → “hambre”
- “Raichu es un” → “pokémon”

Dado que este tipo de IA es entrenada con técnicas de aprendizaje profundo, técnicamente no puede recibir strings, por lo que pasa por el siguiente proceso:

Un modelo de lenguaje es un tipo de IA que permite predecir la palabra más probable que le sigue a una frase. Por ejemplo:

- “No he comido y tengo” → “hambre”
- “Raichu es un” → “pokémon”


Dado que este tipo de IA es entrenada con técnicas de aprendizaje profundo, técnicamente no puede recibir strings, por lo que pasa por el siguiente proceso:




Para evaluar que un modelo de lenguaje funcione correctamente, existen diferentes formas de evaluarlo. Unas de estas se conoce como **next-token-prediction**:

Interrogación 2025-1

Para evaluar que un modelo de lenguaje funcione correctamente, existen diferentes formas de evaluarlo. Unas de estas se conoce como **next-token-prediction**:




Para evaluar que un modelo de lenguaje funcione correctamente, existen diferentes formas de evaluarlo. Unas de estas se conoce como **next-token-prediction**:



Otro método de evaluación se conoce como **multiple-choice**, el cual funciona similar a **next-token-prediction**, pero chequea que la predicción se encuentre entre un grupo de posibles resultados esperados.

Para evaluar que un modelo de lenguaje funcione correctamente, existen diferentes formas de evaluarlo. Unas de estas se conoce como **next-token-prediction**:



Otro método de evaluación se conoce como **multiple-choice**, el cual funciona similar a **next-token-prediction**, pero chequea que la predicción se encuentre entre un grupo de posibles resultados esperados.

Para ambos métodos, se usa la métrica **precisión** para medir la efectividad del modelo

El proyecto LMEval es una primera versión de un sistema de evaluación de LLMs. Su clase de entrada es `Evaluator.cs` y gestiona la evaluación de dos tipos de Modelos.

El proyecto LMEval es una primera versión de un sistema de evaluación de LLMs. Su clase de entrada es `Evaluator.cs` y gestiona la evaluación de dos tipos de Modelos.

`Evaluator.cs` tiene un método de entrada que recibe un `EvaluationRequest` con información sobre lo que el usuario quiere hacer. En particular:

- Recibe el nombre del modelo que se quiere evaluar, el método de evaluación que se quiere utilizar, el dataset que se quiere usar en la evaluación y, opcionalmente, una ruta a un directorio para guardar el resultado.
- Inicializa un Tokenizador y carga el dataset
- Evalúa al modelo seleccionado con el método de evaluación seleccionado
- Si se especifica, guarda en una ruta el resultado de la evaluación

El proyecto LMEval es una primera versión de un sistema de evaluación de LLMs. Su clase de entrada es `Evaluator.cs` y gestiona la evaluación de dos tipos de Modelos.

`Evaluator.cs` tiene un método de entrada que recibe un `EvaluationRequest` con información sobre lo que el usuario quiere hacer. En particular:

- Recibe el nombre del modelo que se quiere evaluar, el método de evaluación que se quiere utilizar, el dataset que se quiere usar en la evaluación y, opcionalmente, una ruta a un directorio para guardar el resultado.
- Inicializa un Tokenizador y carga el dataset
- Evalúa al modelo seleccionado con el método de evaluación seleccionado
- Si se especifica, guarda en una ruta el resultado de la evaluación

`Evaluate(...)` retorna un objeto de tipo `Result` con información sobre la ejecución de la `EvaluationRequest` (Si la request fue exitosa y el resultado de la evaluación).