

# EYP 1025-1027 Modelos Probabilísticos

## Clase 14

Profesor: Reinaldo B. Arellano-Valle

Departamento de Estadística  
Pontificia Universidad Católica de Chile



# Contenido I

- 1 Esperanza y Varianza de Vectores Aleatorios
  - Vector esperado y matriz de varianza-covarianza
  - Matriz de covarianza
  - Ejemplos
- 2 Matriz de correlación
  - Ejemplo
  - Propiedades básicas
- 3 Distribuciones Multivariadas Especiales
  - Distribución Multinomial
  - Distribución Normal Multivariada
  - Ejemplo: Normal Bivariada

# Esperanza y Varianza de Vectores Aleatorios

## Vector esperado y matriz de varianza-covarianza

A continuación, se generalizán los conceptos de esperanza y varianza de una variable aleatoria a un vector aleatorio. Para esto, el álgebra requerida se desarrollará en términos de vectores columna.

### Definición 1.1

**Esperanza de un vector aleatorio** Sea  $\mathbf{X} = (X_1, \dots, X_n)^T$  un vector aleatorio de dimensión  $n$ . La esperanza de  $\mathbf{X}$ , denotado como  $E(\mathbf{X})$ , se define como,

$$E(\mathbf{X}) = (E(X_1), E(X_2), \dots, E(X_n))^T.$$

Es decir, si  $\boldsymbol{\mu} := E(\mathbf{X})$  y  $\mu_i = E(X_i)$  para  $i = 1, \dots, n$ , entonces  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$  y también se llama **vector esperado**.

# Esperanza y Varianza de Vectores Aleatorios

## Definición 1.2

**Matriz de varianza-covarianza** Sea  $\mathbf{X} = (X_1, \dots, X_n)^T$  un vector aleatorio de dimensión  $n$ . La matriz de varianza-covarianza de  $\mathbf{X}$  se define como,

$$\begin{aligned}\text{Var}(\mathbf{X}) &= \text{E}([\mathbf{X} - \text{E}(\mathbf{X})][\mathbf{X} - \text{E}(\mathbf{X})]^T) \\ &= \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Var}(X_n) \end{pmatrix}.\end{aligned}$$

Es decir, si  $\mathbf{\Sigma} := \text{Var}(\mathbf{X})$  y  $\sigma_{ij} = \text{Cov}(X_i, X_j) = \text{E}\{(X_i - \mu_i)(X_j - \mu_j)\}$ ,  $i, j = 1, \dots, n$ , entonces  $\mathbf{\Sigma} = ((\sigma_{ij}))_{i,j=1,\dots,n}$ .

# Esperanza y Varianza de Vectores Aleatorios

## Matriz de covarianza

Como una extensión de la matriz de varianza-covarianza, se define la matriz de covarianzas entre dos vectores aleatorios.

### Definición 1.3

**Matriz de covarianza** Sean  $\mathbf{X} = (X_1, \dots, X_n)^T$  e  $\mathbf{Y} = (Y_1, \dots, Y_m)^T$  dos vectores aleatorios definidos en un mismo espacio de probabilidad. La matriz de covarianza entre  $\mathbf{X}$  e  $\mathbf{Y}$  se define como,

$$\begin{aligned} \text{Cov}(\mathbf{X}, \mathbf{Y}) &= E([\mathbf{X} - E(\mathbf{X})][\mathbf{Y} - E(\mathbf{Y})]^T) \\ &= \begin{pmatrix} \text{Cov}(X_1, Y_1) & \text{Cov}(X_1, Y_2) & \dots & \text{Cov}(X_1, Y_m) \\ \text{Cov}(X_2, Y_1) & \text{Cov}(X_2, Y_2) & \dots & \text{Cov}(X_2, Y_m) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, Y_1) & \text{Cov}(X_n, Y_2) & \dots & \text{Cov}(X_n, Y_m) \end{pmatrix}. \end{aligned}$$

# Esperanza y Varianza de Vectores Aleatorios

## Ejemplos

### Ejemplo 1.1

Sean  $X$  e  $Y$  variables aleatorias con fmp conjunta dada por,

$x \backslash y$	0	1	$P(X=x)$
-1	$1/7$	$1/7$	$2/7$
0	$2/7$	$1/7$	$3/7$
1	$1/7$	$1/7$	$2/7$
$P(Y=y)$	$4/7$	$3/7$	1

Es claro que,

$$E(X) = -1 \times \frac{2}{7} + 1 \times \frac{2}{7} = 0,$$

$$\text{Var}(X) = E(X^2) = 2 \times \frac{2}{7} = \frac{4}{7},$$

## Esperanza y Varianza de Vectores Aleatorios

$$E(Y) = 1 \times \frac{3}{7} = \frac{3}{7},$$

$$\text{Var}(Y) = \left(0 - \frac{3}{7}\right)^2 \times \frac{4}{7} + \left(1 - \frac{3}{7}\right)^2 \times \frac{3}{7} = \frac{12}{49},$$

$$\begin{aligned}\text{Cov}(X, Y) &= E(XY) - E(X)E(Y) \\ &= -1 \times 1 \times \frac{1}{7} + 1 \times 1 \times \frac{1}{7} - 0 \times \frac{3}{7} = 0.\end{aligned}$$

Entonces, el vector de medias y la matriz de varianza-covarianza de  $\mathbf{X} = (X, Y)^\top$  están dadas por,

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 3/7 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} 4/7 & 0 \\ 0 & 12/49 \end{pmatrix}.$$

# Covarianza

## Ejemplo 1.2

Sea  $(X, Y)$  un vector aleatorio con fdp conjunta dada por,

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{x} & \text{si } 0 < x \leq 1, 0 < y \leq x \\ 0 & \text{eoc} \end{cases}$$

En esta caso tenemos,

$$E(X) = \int_0^1 \int_y^1 x \frac{1}{x} dx dy = \frac{1}{2},$$

$$E(Y) = \int_0^1 \int_0^x y \frac{1}{x} dy dx = \frac{1}{4},$$

$$E(X^2) = \int_0^1 \int_0^x x^2 \frac{1}{x} dy dx = \frac{1}{3} \implies \text{Var}(X) = \frac{1}{3} - \frac{1}{2^2},$$



## Esperanza y Varianza de Vectores Aleatorios

$$E(Y^2) = \int_0^1 \int_0^x y^2 \frac{1}{x} dy dx = \frac{1}{9} \implies \text{Var}(Y) = \frac{1}{9} - \frac{1}{4^2},$$

$$E(XY) = \int_0^1 \int_0^x xy \frac{1}{x} dy dx = \frac{1}{6} \implies \text{Cov}(X, Y) = \frac{1}{6} - \frac{1}{2} \frac{1}{4}.$$

Por lo tanto, el valor esperado  $\boldsymbol{\mu} = E(\mathbf{X})$  está dado por,

$$E(\mathbf{X}) = \boldsymbol{\mu} = \begin{pmatrix} 1/2 \\ 1/4 \end{pmatrix},$$

y la matriz de varianza-covarianza  $\boldsymbol{\Sigma} = \text{Var}(\mathbf{X})$  es,

$$\boldsymbol{\Sigma} = \begin{pmatrix} 1/12 & 1/24 \\ 1/24 & 7/144 \end{pmatrix}.$$

# Esperanza y Varianza de Vectores Aleatorios

## Matriz de correlación

### Definición 2.1

**Matriz de Correlación** Sea  $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$  un vector aleatorio  $n$  dimensional. La matriz de correlación de  $\mathbf{X}$ , denotada como  $\mathbf{R}$ , se define como,

$$\mathbf{R} = \begin{pmatrix} 1 & \rho_{X_1, X_2} & \cdots & \rho_{X_1, X_n} \\ \rho_{X_2, X_1} & 1 & \cdots & \rho_{X_2, X_n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{X_n, X_1} & \rho_{X_n, X_2} & \cdots & 1 \end{pmatrix}.$$

De forma similar se define la matriz de correlación

$\mathbf{R}_{XY} = ((\rho_{X_i, Y_j}))_{n \times m}$  entre dos vectores aleatorios  $\mathbf{X} = (X_1, \dots, X_n)^T$  e  $\mathbf{Y} = (Y_1, \dots, Y_m)^T$ , de modo que la matriz  $\mathbf{R}$  se tiene para  $\mathbf{Y} = \mathbf{X}$ .

# Esperanza y Varianza de Vectores Aleatorios

## Ejemplo

### Ejemplo 2.1

Sea  $\mathbf{X} = (X, Y)^T$  un vector aleatorio bi-dimensional con fdp conjunta dada por,

$$f(x, y) = \begin{cases} 2 & \text{si } 0 < x < y, 0 < y < 1 \\ 0 & \text{eoc} \end{cases}$$

Tenemos que,

$$E(X) = \int_0^1 \int_0^y 2x dx dy = \frac{1}{3}$$

$$E(Y) = \int_0^1 \int_x^1 2y dy dx = \frac{2}{3},$$

## Esperanza y Varianza de Vectores Aleatorios

$$\text{Var}(X) = \int_0^1 \int_0^y 2 \left( x - \frac{1}{3} \right)^2 dx dy = \frac{1}{18}$$

$$\text{Var}(Y) = \int_0^1 \int_x^1 2 \left( y - \frac{2}{3} \right)^2 dy dx = \frac{1}{18}$$

$$\text{Cov}(X, Y) = \int_0^1 \int_0^y 2 \left( x - \frac{1}{3} \right) \left( y - \frac{2}{3} \right) dx dy = \frac{1}{36}.$$

Por lo tanto la matriz de correlación está dada por,

$$\mathbf{R} = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1 \end{pmatrix}.$$

# Esperanza y Varianza de Vectores Aleatorios

## Propiedades básicas

$$1) E(\mathbf{AX} + \mathbf{b}) = \mathbf{AE}(\mathbf{X}) + \mathbf{b} \text{ y } \text{Var}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\text{Var}(\mathbf{X})\mathbf{A}^\top$$

$$2a) \Sigma = \text{Var}(\mathbf{X}) \text{ es una matriz simétrica, } \Sigma = ((\sigma_{ij})) = ((\sigma_{ji})) = \Sigma^\top$$

$$2b) \Sigma = \text{Var}(\mathbf{X}) \text{ es una matriz semidefinida positiva (s.d.p.), es decir, } \mathbf{a}^\top \Sigma \mathbf{a} \geq 0 \quad \forall \mathbf{a} \in \mathbb{R}^n$$

$$2c) \Sigma = \text{Var}(\mathbf{X}) \text{ es una matriz definida positiva (d.p.), es decir, } \mathbf{a}^\top \Sigma \mathbf{a} \geq 0 \quad \forall \mathbf{a} \neq \mathbf{0} \iff X_1, \dots, X_n \text{ son linealmente independientes.}$$

$$3) \text{Cov}(\mathbf{X}, \mathbf{Y}) = E(\mathbf{XY}^\top) - E(\mathbf{X})E(\mathbf{Y})^\top, \text{Cov}(\mathbf{X}, \mathbf{X}) = \text{Var}(\mathbf{X}) \text{ y } \text{Cov}(\mathbf{AX} + \mathbf{C}, \mathbf{BY} + \mathbf{D}) = \mathbf{ACov}(\mathbf{X}, \mathbf{Y})\mathbf{B}^\top.$$

Note que  $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \text{Cov}(\mathbf{Y}, \mathbf{X})^\top$ , de modo que

$$\text{Var}(\mathbf{X} \pm \mathbf{Y}) = \text{Var}(\mathbf{X}) + \text{Var}(\mathbf{Y}) \pm \text{Cov}(\mathbf{X}, \mathbf{Y}) \pm \text{Cov}(\mathbf{Y}, \mathbf{X}).$$

## Esperanza y Varianza de Vectores Aleatorios

Para demostrar las Propiedades 2b) y 2c) de la matriz de varianza-covarianza  $\Sigma = \text{Var}(\mathbf{X})$ , sea

$$Y = \sum_{i=1}^n a_i X_i = (a_1, \dots, a_n) \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} = \mathbf{a}^\top \mathbf{X}$$
$$\implies \text{Var}(Y) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(X_i, X_j) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \sigma_{ij} = \mathbf{a}^\top \Sigma \mathbf{a}.$$

Pero, para toda variable aleatoria  $Y$ ,

$$\text{Var}(Y) \geq 0 \implies \mathbf{a}^\top \Sigma \mathbf{a} \geq 0 \quad \forall \mathbf{a}$$
$$\stackrel{\text{def.}}{\iff} \Sigma \text{ es s.d.p. } (\Sigma \geq 0)$$

# Esperanza y Varianza de Vectores Aleatorios

Para  $\mathbf{a} \neq \mathbf{0}$ :

$$\begin{aligned}\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a} > 0 &\iff Y = \sum_{i=1}^n a_i X_i \neq \text{constante} \\ &\iff X_1, \dots, X_n \text{ son linealmente independientes} \\ &\stackrel{\text{def.}}{\iff} \Sigma \text{ es d.p. } (\Sigma > 0, \text{ e.d. } |\Sigma| > 0),\end{aligned}$$

y

$$\begin{aligned}\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a} = 0 &\iff Y = \sum_{i=1}^n a_i X_i = \text{constante} \\ &\iff X_1, \dots, X_n \text{ son linealmente dependientes} \\ &\stackrel{\text{def.}}{\iff} \Sigma \text{ es d.p. } (\Sigma \geq 0, \text{ e.d. } |\Sigma| = 0).\end{aligned}$$

# Distribuciones Multivariadas Especiales

## Distribución Multinomial

Considere un experimento aleatorio con  $k$  resultados posibles  $R_1, \dots, R_k$  exhaustivos y mutuamente excluyentes, es decir,

$$\cup_{i=1}^k R_i = \Omega \quad \text{y} \quad R_i \cap R_j = \emptyset \quad \forall i \neq j$$

Sea  $p_i = P(R_i)$ ,  $i = 1, \dots, k$ ,

$$\implies p_i \geq 0 \quad \forall i \quad \text{y} \quad \sum_{i=1}^k p_i = 1. \quad (3.1)$$

Para  $n$  repeticiones independientes de este experimento, defina las variables aleatorias,

$X_i =$  número de veces que ocurre  $R_i$ ,  $i = 1, \dots, k$ ,

$$\implies X_i(\omega) \in \mathcal{X}_i = \{0, 1, \dots, n\} \quad \forall i \quad \text{y} \quad \sum_{i=1}^k X_i(\omega) = n \quad \forall \omega \in \Omega.$$



## Distribuciones Multivariadas Especiales

Luego, en  $n$  repeticiones independientes, la probabilidad del evento

$$\begin{aligned}\{X_1 = x_1, \dots, X_k = x_k\} &:= \cap_{i=1}^k \{X_i = x_i\} \\ &= \cap_{i=1}^k \{R_i \text{ ocurre exactamente } x_i \text{ veces}\},\end{aligned}$$

esta dada por,

$$P(X_1 = x_1, \dots, X_k = x_k) = \begin{cases} \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k} & \text{si } (x_1, \dots, x_k) \in \mathcal{X}, \\ 0 & \text{eoc.} \end{cases} \quad (3.2)$$

donde  $\mathcal{X} = \{(x_1, \dots, x_k) : x_i = 1, \dots, n, \sum_{i=1}^k x_i = n\}$  es el recorrido conjunto de  $X_1, \dots, X_k$ .

# Distribuciones Multivariadas Especiales

## Definición 3.1

Se dice que un vector aleatorio discreto  $(X_1, \dots, X_k)$  tiene distribución multinomial con parámetros  $n$  y  $(p_1, \dots, p_k)$ , si las variables aleatorias  $X_1, \dots, X_k$  tienen fmp conjunta dada por (3.2); en tal caso, se escribe,

$$(X_1, \dots, X_k) \sim Mult(n, p_1, \dots, p_k),$$

donde  $n \in \{1, 2, \dots\}$  y  $p_1, \dots, p_k$  satisfacen (3.1).

**Nota:** Como  $\sum_{i=1}^n X_i = n \implies X_1, \dots, X_k$  son linealmente dependientes  $\implies$  basta con especificar la distribución conjunta de  $X_1, \dots, X_{k-1}$ , ya que  $X_k = n - \sum_{i=1}^{k-1} X_i$ .

# Distribuciones Multivariadas Especiales

## Ejemplo 3.1

En 12 lanzamientos de un dado honesto, sea  $X_i$  = número de veces que aparece el  $i$ -ésimo resultado,  $i = 1, \dots, 6$ . Entonces,

$$(X_1, \dots, X_6) \sim \text{Mult}(n = 10, p_1 = 1/6, \dots, p_6 = 1/6).$$

Así,

$$P(X_1 = 2, X_2 = 3, X_3 = 2, X_4 = 2, X_5 = 2, X_6 = 3) = \frac{12!}{(2!)^3(3!)^3} (1/6)^{12}.$$

# Distribuciones Multivariadas Especiales

**Propiedades:** Si  $(X_1, \dots, X_k) \sim Mult(n, p_1, \dots, p_k)$ , entonces,

1) La fmg conjunta de  $X_1, \dots, X_k$  es,

$$\begin{aligned} M_{X_1, \dots, X_k}(t_1, \dots, t_k) &= E\left(e^{\sum_{i=1}^k t_i X_i}\right) \\ &= \sum_{(x_1, \dots, x_k) \in \mathcal{X}} e^{\sum_{i=1}^k t_i x_i} \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k} \\ &= \sum_{(x_1, \dots, x_k) \in \mathcal{X}} \frac{n!}{x_1! \cdots x_k!} (p_1 e^{t_1})^{x_1} \cdots (p_k e^{t_k})^{x_k} \\ &= (p_1 e^{t_1} + \cdots + p_k e^{t_k})^n \quad \forall (t_1, \dots, t_k) \in \mathbb{R}^k \\ &\quad \text{(teorema del multinomio)} \end{aligned}$$

$$\begin{aligned} \implies M_{X_1, \dots, X_m}(t_1, \dots, t_m) &= M_{X_1, \dots, X_m, X_{m+1}, \dots, X_k}(t_1, \dots, t_m, 0, \dots, 0) \\ &= \{p_1 e^{t_1} + \cdots + p_m e^{t_m} + 1 - (p_1 + \cdots + p_m)\}^n, \\ &\quad m = 1, \dots, k-1. \end{aligned}$$

## Distribuciones Multivariadas Especiales

2) Para todo  $m = 1, \dots, k-1$ ,

$$(X_1, \dots, X_m; n - \sum_{i=1}^m X_i) \sim Mult(n; p_1, \dots, p_m; 1 - \sum_{i=1}^m p_i).$$

En particular,

$$(X_i; n - \sum_{l \neq i} X_l) \sim Bin(n, p_i; \overbrace{1 - \sum_{l \neq i} p_l}^{1-p_i}) \iff X_i \sim Bin(n, p_i)$$

$$\implies E(X_i) = np_i \text{ y } \text{Var}(X_i) = np_i(1 - p_i), \quad i = 1, \dots, k,$$

$$(X_i, X_j; n - \sum_{l \neq i, j} X_l) \sim Trin(n; p_i, p_j; \overbrace{1 - \sum_{l \neq i, j} p_l}^{1-(p_i+p_j)})$$

$$\iff (X_i, X_j) \sim Trin(n; p_i, p_j) \implies \text{Cov}(X_i, X_j) = -np_i p_j \quad \forall i \neq j.$$

## Distribuciones Multivariadas Especiales

3) Suponga que se reagrupan los resultados  $R_1, \dots, R_k$  en  $m$  grupos exhaustivos y excluyentes  $S_1, \dots, S_m$ , es decir,

$$\cup_{j=1}^m S_j = \Omega \quad \text{y} \quad S_i \cap S_j = \emptyset \quad \forall i \neq j,$$

de modo que

$$P(S_j) = \pi_j \geq 0, \quad j = 1, \dots, m, \quad \text{y} \quad \sum_{j=1}^m \pi_j = 1.$$

Sea  $Y_j$  = número de veces que ocurre  $S_j$  en las  $n$  repeticiones independientes,  $j = 1, \dots, m$ . Entonces,

$$(Y_1, \dots, Y_m) \sim \text{Mult}(n, \pi_1, \dots, \pi_m).$$

# Distribuciones Multivariadas Especiales

## Distribución Normal Multivariada

Sea  $\mathbf{Z} = (Z_1, \dots, Z_m)^\top$ , donde  $Z_1, \dots, Z_m$  son variables aleatorias iid  $N(0, 1)$ . Entonces,

$$\begin{aligned} f_{\mathbf{Z}}(\mathbf{z}) &= f_{Z_1, \dots, Z_m}(z_1, \dots, z_m) \\ &= \prod_{i=1}^m f_{Z_i}(z_i) \quad (\text{hip. de independencia}) \\ &= \prod_{i=1}^m (2\pi)^{-1/2} e^{-\frac{1}{2}z_i^2} \quad (Z_i \sim N(0, 1) \quad \forall i) \\ &= (2\pi)^{-m/2} e^{-\frac{1}{2} \sum_{i=1}^m z_i^2} \quad z_i \in \mathbb{R} \quad \forall i, \\ &= (2\pi)^{-m/2} e^{-\frac{1}{2} \mathbf{z}^\top \mathbf{z}} \quad \mathbf{z} = (z_1, \dots, z_m)^\top \in \mathbb{R}^m. \end{aligned}$$

# Distribuciones Multivariadas Especiales

Además,

$$\begin{aligned}M_{\mathbf{Z}}(\mathbf{t}) &= M_{Z_1, \dots, Z_m}(t_1, \dots, t_m) \\&= \prod_{i=1}^m M_{Z_i}(t_i) \quad (\text{hip. de independencia}) \\&= \prod_{i=1}^m e^{\frac{1}{2}t_i^2} \quad (Z_i \sim N(0, 1) \quad \forall i) \\&= e^{-\frac{1}{2} \sum_{i=1}^m t_i^2} \quad t_i \in \mathbb{R} \quad \forall i, \\&= e^{-\frac{1}{2} \mathbf{t}^\top \mathbf{t}} \quad \mathbf{t} = (t_1, \dots, t_m)^\top \in \mathbb{R}^m.\end{aligned}$$



# Distribuciones Multivariadas Especiales

Note también que:

$$\begin{aligned} E(Z_i) &= 0, \quad i = 1, \dots, m, \quad \text{y} \\ \text{Cov}(Z_i, Z_j) &= \begin{cases} 1 & \text{si } i = j, \quad i, j = 1, \dots, m, \\ 0 & \text{si } i \neq j, \quad i, j = 1, \dots, m. \end{cases} \\ \implies \begin{cases} E(\mathbf{Z}) = (E(Z_1), \dots, E(Z_m))^T = \mathbf{0} \in \mathbb{R}^m, \quad \text{y} \\ \text{Var}(\mathbf{Z}) = ((\text{Cov}(Z_i, Z_j))) = \mathbf{I}_m. \end{cases} \end{aligned}$$

Sean  $X_i = \sum_{j=1}^n a_{ij}Z_j + \mu_i$  para  $i = 1, \dots, n$ , donde  $a_{ij}$  y  $\mu_i$ ,  $i, j = 1, \dots, n$ , son constantes reales. Defina  $\mathbf{X} = (X_1, \dots, X_n)^T$ ,  $\mathbf{A} = ((a_{ij}))$  y  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$ . Matricialmente, se tiene que

$$\mathbf{X} = \mathbf{AZ} + \boldsymbol{\mu}, \quad \mathbf{A} \in \mathbb{R}^{n \times m}, \quad \boldsymbol{\mu} \in \mathbb{R}^{n \times 1}.$$

# Distribuciones Multivariadas Especiales

Entonces,

$$\mathbf{E}(\mathbf{X}) = \mathbf{E}(\mathbf{AZ} + \boldsymbol{\mu}) = \mathbf{A}\mathbf{E}(\mathbf{Z}) + \boldsymbol{\mu} = \boldsymbol{\mu} \quad (\mathbf{E}(\mathbf{Z}) = \mathbf{0}),$$

$$\text{Var}(\mathbf{X}) = \text{Var}(\mathbf{AZ} + \boldsymbol{\mu}) = \mathbf{A}\text{Var}(\mathbf{Z})\mathbf{A}^\top = \mathbf{A}\mathbf{A}^\top := \boldsymbol{\Sigma} \quad (\text{Var}(\mathbf{Z}) = \mathbf{I}_n).$$

Además,

$$\begin{aligned} M_{\mathbf{X}}(\mathbf{t}) &= \mathbf{E}\left(e^{\mathbf{t}^\top \mathbf{X}}\right) \\ &= \mathbf{E}\left(e^{\mathbf{t}^\top (\mathbf{AZ} + \boldsymbol{\mu})}\right) \\ &= \mathbf{E}\left(e^{\mathbf{t}^\top \mathbf{AZ} + \mathbf{t}^\top \boldsymbol{\mu}}\right) \\ &= e^{\mathbf{t}^\top \boldsymbol{\mu}} \mathbf{E}\left(e^{(\mathbf{A}^\top \mathbf{t})^\top \mathbf{Z}}\right) \\ &= e^{\mathbf{t}^\top \boldsymbol{\mu}} M_{\mathbf{Z}}\left(\mathbf{A}^\top \mathbf{t}\right) \\ &= e^{\mathbf{t}^\top \boldsymbol{\mu}} e^{\frac{1}{2}(\mathbf{A}^\top \mathbf{t})^\top (\mathbf{A}^\top \mathbf{t})} \\ &= e^{\mathbf{t}^\top \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^\top \mathbf{A} \mathbf{A}^\top \mathbf{t}} \\ &= e^{\mathbf{t}^\top \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^\top \boldsymbol{\Sigma} \mathbf{t}}, \quad \mathbf{t} \in \mathbb{R}^n. \end{aligned}$$

# Distribuciones Multivariadas Especiales

## Definición 3.2

Se dice que un vector aleatorio  $\mathbf{X} = (X_1, \dots, X_n)^\top$  tiene distribución normal  $n$ -variada con vector de medias  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^\top$  y matriz de varianza-covarianza  $\boldsymbol{\Sigma} = ((\sigma_{ij}))_{i,j=1,\dots,n}$ , lo cual se escribe como  $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , ssi

$$\mathbf{X} = \mathbf{AZ} + \boldsymbol{\mu},$$

donde  $\mathbf{AA}^\top = \boldsymbol{\Sigma}$  y  $\mathbf{Z} = (Z_1, \dots, Z_m)^\top \sim N_m(\mathbf{0}, \mathbf{I}_m)$ , es decir,  $Z_1, \dots, Z_m \stackrel{iid}{\sim} N(0, 1)$ . En otras palabras,

$$\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \stackrel{\text{def.}}{\iff} M_{\mathbf{X}}(\mathbf{t}) = e^{\mathbf{t}^\top \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^\top \boldsymbol{\Sigma} \mathbf{t}}, \quad \mathbf{t} \in \mathbb{R}^n.$$

Equivalentemente, si  $\boldsymbol{\Sigma} > 0$  (matriz definida positiva), entonces,

$$\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \stackrel{\text{def.}}{\iff} f_{\mathbf{X}}(\mathbf{x}) = (2\pi)^{-n/2} |\boldsymbol{\Sigma}|^{-1/2} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})},$$
$$\mathbf{x} \in \mathbb{R}^n.$$

# Distribuciones Multivariadas Especiales

**Propiedades básicas:** Sea  $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Entonces:

1)  $\mathbf{BX} + \mathbf{b} \sim N_m(\mathbf{B}\boldsymbol{\mu} + \mathbf{b}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^\top)$  para cualquier matriz  $\mathbf{B} \in \mathbb{R}^{m \times n}$  y vector  $\mathbf{b} \in \mathbb{R}^{m \times 1}$ .

*Demostración:* Use fgm.

En particular, si  $\boldsymbol{\Sigma} > 0$ , entonces  $\boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu}) \sim N_n(\mathbf{0}, \mathbf{I}_n)$ , donde  $\mathbf{B} = \boldsymbol{\Sigma}^{-1/2} = (\boldsymbol{\Sigma}^{1/2})^{-1}$  y  $\boldsymbol{\Sigma}^{1/2}$  es la única raíz cuadrada simétrica de  $\boldsymbol{\Sigma}$ .

## Distribuciones Multivariadas Especiales

2) Considere la partición,

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \longrightarrow \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \quad \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix},$$

donde los  $\mathbf{X}_j$ 's y  $\boldsymbol{\mu}_j$ 's son vectores  $n_j \times 1$ , los  $\boldsymbol{\Sigma}_{ij}$ 's son matrices  $n_i \times n_j$  y  $n_1 + n_2 = n$ . Entonces:

a)  $\mathbf{X}_j \sim N_{n_j}(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_{jj})$ ,  $j = 1, 2$ , donde  $n_1 + n_2 = n$ .

*Demostración:* Use la Propiedad 1), colocando  $\mathbf{b} = \mathbf{0}$  y  $\mathbf{B} = (\mathbf{I}_{n_1}, \mathbf{0})$  para  $j = 1$ , y  $\mathbf{B} = (\mathbf{0}, \mathbf{I}_{n_1})$  para  $j = 2$ .

b)  $\mathbf{X}_1$  y  $\mathbf{X}_2 \iff \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21}^\top = \mathbf{0}$ .

*Demostración:* Use fgm.

3) Si  $\boldsymbol{\Sigma} > 0$ , entonces  $(\mathbf{X} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_n^2$ .

# Distribución Normal Bivariada

## Ejemplo: Normal Bivariada

### Ejemplo 3.2

Para  $n = 2$  con  $X_1 = X$  y  $X_2 = Y$ , se tiene la distribución normal bivariada dada por

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2 \left( \boldsymbol{\mu} = \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix} \right),$$

donde  $\mu_X = E(X)$ ,  $\mu_Y = E(Y)$ ,  $\sigma_X^2 = \text{Var}(X)$ ,  $\sigma_Y^2 = \text{Var}(Y)$  y  $\sigma_{XY} = \text{Cov}(X, Y)$ . Note que

$$\sigma_{XY} = \rho_{XY} \sigma_X \sigma_Y,$$

donde  $\rho_{XY}$  es el coeficiente de correlación entre  $X$  e  $Y$ , y  $\sigma_X$  y  $\sigma_Y$  son las desviaciones estándar de  $X$  e  $Y$ , respectivamente.

# Distribución Normal Bivariada

## Ejemplo: Normal Bivariada

Si  $-1 < \rho_{XY} < 1$ , entonces  $\Sigma > 0$  y, por lo tanto, es invertible. En tal caso,  $(X, Y)$  tiene fdp normal bivariada dada por,

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho_{XY}^2}} \exp \left\{ -\frac{1}{2(1-\rho_{XY}^2)} \left[ \left( \frac{x-\mu_X}{\sigma_X} \right)^2 - 2\rho_{XY} \left( \frac{x-\mu_X}{\sigma_X} \right) \left( \frac{y-\mu_Y}{\sigma_Y} \right) + \left( \frac{y-\mu_Y}{\sigma_Y} \right)^2 \right] \right\},$$

para  $-\infty < x < \infty$  y  $-\infty < y < \infty$ .

## Distribución Normal Bivariada

Aunque la fdp anterior parece complicada, la distribución normal bivariada es una de las más utilizadas. Algunas de sus muchas propiedades incluyen,

- i) La distribución marginal de  $X$  es  $N(\mu_X, \sigma_X^2)$
- ii) La distribución marginal de  $Y$  es  $N(\mu_Y, \sigma_Y^2)$
- iii)  $\rho_{XY} = 0 \iff X$  e  $Y$  son independientes
- iv) Para constantes cualquiera  $a$  y  $b$ , la distribución de  $aX + bY$  es  $N(a\mu_X + b\mu_Y, a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\rho_{XY}\sigma_X\sigma_Y)$



## Distribución Normal Bivariada




Figura 1: Densidad normal bivariada con  $\mu_X = \mu_Y = 0$ ,  $\sigma_X = \sigma_Y = 1$  y  $\rho_{XY} = 0$ .

## Distribución Normal Bivariada

### Ejemplo 3.3

Suponga que se selecciona al azar una pareja formada por un hombre y una mujer de una determinada población. Sea  $X$  la altura de la mujer e  $Y$  la altura del hombre, ambas medidas en pulgadas. Se sabe que la distribución conjunta de  $X$  e  $Y$  es normal bivariada con medias  $\mu_X = 66.8$  y  $\mu_Y = 70$ , desviaciones estándar  $\sigma_X = \sigma_Y = 2$ , y correlación  $\rho_{XY} = 0.68$ . Calcule la probabilidad de que la mujer sea más alta que el hombre, es decir,  $P(X - Y > 0)$ .

## Distribución Normal Bivariada

Dado que  $(X, Y)$  tienen una distribución normal bivariada, se tiene que la distribución de  $X - Y$  también es normal, con una media

$$E(X - Y) = 66.8 - 70 = -3.2$$

y varianza

$$\begin{aligned}\text{Var}(X - Y) &= \sigma_X^2 + \sigma_Y^2 - 2\text{Cov}(X, Y) \\ &= 4 + 4 - 2(0.68)(2)(2) = 2.56.\end{aligned}$$

Luego, como la desviación estándar de  $X - Y$  es  $\sigma_{X-Y} = 1.6$ , entonces la estandarización de  $X - Y$  es  $Z = (X - Y + 3.2)/1.6 \sim N(0, 1)$ .

Luego,

$$\begin{aligned}P(X - Y > 0) &= P(Z > 2) = 1 - \Phi(2) \\ &= 0.0227\end{aligned}$$