

# EYP1027 Modelos Probabilísticos

## Clase 7

Profesor: Reinaldo B. Arellano-Valle

Departamento de Estadística  
Pontificia Universidad Católica de Chile

Segundo Semestre 2020



# Contenido I

## 1 Momentos y Funciones Generadoras

- Momentos
- Algunas propiedades
- Ejemplos
- Función generadora de momento
- Ejemplos
- Algunas propiedades

## Momentos y Funciones Generadoras

Recordemos que si  $X$  es una variable aleatoria en  $(\Omega, \mathcal{A}, P)$  y  $g$  es una función con dominio y recorrido en los reales, entonces  $g(X)$  también es una variable aleatoria en  $(\Omega, \mathcal{A}, P)$ , y su esperanza puede ser calculada como,

$$E\{g(X)\} = \begin{cases} \sum_{x \in \mathcal{X}} g(x) f_X(x) & \text{si } X \text{ es discreta ,} \\ \int_{-\infty}^{\infty} g(x) f_X(x) dx & \text{si } X \text{ es continua ,} \end{cases}$$

siempre que exista la  $\sum$  o la  $\int$ . Como fue dicho antes, si  $E(|g(X)|) = \infty$ , decimos que  $E\{g(X)\}$  no existe.

En particular, la media  $\mu_X := E(X)$  y la varianza  $\sigma_X^2 := E\{(X - \mu_X)^2\}$  se obtienen para  $g(x) = x$  y  $g(x) = (x - \mu_X)^2$ , respectivamente. Tales características constituyen casos especiales de los denominados momentos no centrados y centrados de la variable aleatoria  $X$  (o su distribución).

## Momentos y Funciones generadoras

**Nota:** Si la función  $g$  es muy complicada, la evaluación de  $E\{g(X)\}$  o  $\text{Var}\{g(X)\}$  puede conducir a integraciones (o sumas) complicadas. De aquí que sean muy útiles las aproximaciones siguientes.

### Teorema 1.1

Sea una variable aleatoria  $X$  con  $E(X) = \mu$ , y  $\text{Var}(X) = \sigma^2$ . Si  $g$  es una función a lo menos diferenciable dos veces en el punto  $x = \mu$ , entonces,

$$\begin{aligned} E(Y) &\simeq g(\mu) + \frac{g''(\mu)}{2} \sigma^2 \\ \text{Var}(Y) &\simeq [g'(\mu)]^2 \sigma^2. \end{aligned}$$

# Momentos y Funciones Generadoras

## Momentos

Los momentos de una distribución o variable aleatoria son una clase especial de esperanzas.

### Definición 1.1

Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$ , y asuma que existen las sumatorias o integrales requeridas para cada entero positivo  $k$ :

- i) El  $k$ -ésimo momento no centrado de  $X$ , se define como,

$$E(X^k) = \begin{cases} \sum_{x \in \mathcal{X}} x^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} x^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$k = 1 \implies E(X) = \mu_X$  es la media de  $X$ .

- ii) El  $k$ -ésimo momento centrado de  $X$ , se define como,

$$E\{(X - \mu_X)^k\} = \begin{cases} \sum_{x \in \mathcal{X}} (x - \mu_X)^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} (x - \mu_X)^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$k = 2 \implies E\{(X - \mu_X)^2\} = \sigma_X^2$  es la varianza de  $X$ .

# Momentos y Funciones generadoras

## Definición 1.2

A parte de la media  $\mu_X = E(X)$  y la varianza  $\sigma_X^2 = E\{(X - \mu_X)^2\}$ , las que son medidas de localización y dispersión de la distribución  $X$ , respectivamente, otras dos características de gran interés son los índices de asimetría ( $\gamma_X$ ) y curtosis ( $\kappa_X$ ) de la distribución de  $X$ :

$$\text{a) } \gamma_X = E \left\{ \left( \frac{X - \mu_X}{\sigma_X} \right)^3 \right\} \leftarrow \text{asimetría de la distribución de } X,$$

$$\text{a) } \kappa_X = E \left\{ \left( \frac{X - \mu_X}{\sigma_X} \right)^4 \right\} \leftarrow \text{curtosis de la distribución de } X.$$

Note que tales índices corresponden al los momentos tercero y cuarto, respectivamente, de la variable aleatoria estandarizada  $Z = \frac{X - \mu_X}{\sigma_X}$ , la cual es tal que  $E(Z) = 0$  y  $\text{Var}(Z) = 1$ .

# Momentos y Funciones generadoras

## Algunas propiedades

De forma similar se definen  $E(|X|^k)$  y  $E(|X - \mu_X|^k)$ , llamados momentos absolutos no centrado y centrado de orden  $k$ , respectivamente.

### Teorema 1.2

- a)  $|E(X^k)| \leq E(|X|^k)$ .
- b) Si  $E(X^k)$ ,  $k > 0$ , es finito, entonces  $E\{(X - \mu_X)^k\}$  es finito.
- c) Si  $E(X^k)$ ,  $k > 0$ , es finito, entonces  $E(X^k)$  es finito  $\forall 0 < m < k$ .
- d) Desigualdad de Markov:  $P(|X| \geq \lambda) \leq \frac{E(|X|^k)}{\lambda^k} \quad \forall \lambda > 0 \text{ y } \forall k > 0$ .  
En particular, si la varianza de  $X$  es finita, entonces,

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2} \quad \forall \varepsilon > 0.$$

- e) Si  $X$  es una variable aleatoria arbitraria, con  $k$ -ésimo momento finito, entonces, para  $k = 1, 2, \dots$ , se tiene que,

$$E(X^k) = k \left\{ \int_0^\infty x^{k-1} (1 - F_X(x)) dx - \int_{-\infty}^0 x^{k-1} F_X(x) dx \right\}.$$

# Momentos y Funciones generadoras

## Demostración 1.1

Demostraremos sólo la propiedad c) asumiendo que  $X$  es continua; luego,

$$\begin{aligned} E(|X|^k) &= \int_{-\infty}^{\infty} |x|^k f_X(x) dx \\ &= \int_{|x| < \lambda} |x|^k f_X(x) dx + \int_{|x| \geq \lambda} |x|^k f_X(x) dx \quad \forall \lambda > 0 \\ &\geq \int_{|x| \geq \lambda} |x|^k f_X(x) dx \quad \forall \lambda > 0 \\ &\geq \int_{|x| \geq \lambda} \lambda^k f_X(x) dx = \lambda^k \int_{|x| \geq \lambda} f_X(x) dx \quad \forall \lambda > 0. \end{aligned}$$

Dividiendo en ambos lados por  $\lambda^k$ , se obtiene el resultado. La demostración cuando  $X$  discreta es similar.



# Momentos y Funciones generadoras

## Ejemplos

### Ejemplo 1.1

Bajo ciertas condiciones la tensión superficial de un líquido (dina/cm) está dada por  $S = 2(1 - 0.005T)^{1.2}$  donde  $T$  es la temperatura del líquido (grados centigrados). Suponga que  $T$  es una variable aleatoria continua con la siguiente fdp:

$$f_T(t) = \begin{cases} 3000t^{-4}, & t \geq 10 \\ 0, & \text{eoc.} \end{cases}$$

Luego,

$$E(T) = \int_{10}^{\infty} 3000t^{-3}dt = 15 \text{ (grados centigrados), y}$$

$$\begin{aligned} \text{Var}(T) &= E(T^2) - (15)^2 \\ &= \int_{10}^{\infty} 3000t^{-2}dt - 225 = 75 \text{ (grados centigrados)}^2. \end{aligned}$$

## Momentos y Funciones generadoras

Para calcular  $E(S)$  y  $\text{Var}(S)$  hay que calcular las integrales siguientes:

$$\int_{10}^{\infty} (1 - 0.005t)^{1.2} t^{-4} dt$$
$$\int_{10}^{\infty} (1 - 0.005t)^{2.4} t^{-4} dt$$

En vez de evaluar esas expresiones, se obtendrán aproximaciones para  $E(S)$  y  $\text{Var}(S)$  usando el Teorema 1.1. Para poder usar esas fórmulas hay que calcular  $g'(15)$  y  $g''(15)$ , en donde  $g(t) = 2(1 - 0.005t)^{1.2}$ . Para la primera derivada, se tiene que,

$$g'(t) = 2.4(1 - 0.005t)^{0.2}(-0.005) = -0.012(1 - 0.005t)^{0.2}.$$

Luego

$$g(15) = 1.82 \text{ y } g'(15) = 0.01.$$

## Momentos y Funciones generadoras

De un modo semejante,

$$g''(t) = -0.0024(1 - 0.005t)^{-0.8}(-0.005) = 0.000012(1 - 0.005t)^{-0.8}.$$

Por lo tanto,

$$g''(15) = \frac{0.000012}{(0.925)^{0.8}} = 0^+.$$

Así, se tiene que,

$$E(S) \simeq g(15) + \frac{1}{2}75g''(15) = 1.82 \text{ (dinas /cm)}$$

$$\text{Var}(S) \simeq 75 [g'(15)]^2 = 0.87 \text{ (dinas/cm)}^2.$$

# Momentos y Funciones generadoras

## Ejemplo 1.2

Suponga que  $X$  es una variable aleatoria continua con fdp,

$$f_X(x) = \begin{cases} 1+x, & \text{si } -1 \leq x \leq 0, \\ 1-x, & \text{si } 0 \leq x \leq 1, \\ 0, & \text{si no.} \end{cases}$$

Como  $|X| \leq 1$  (con probabilidad 1), entonces, para todo  $k > 0$ , se tiene que  $|X|^k \leq 1$  (con probabilidad 1). Luego, todos los momentos de  $X$  (centrados o no) son finitos. Además, debido a la simetría de  $f_X(\cdot)$  en torno al cero, es decir,  $f_X(-x) = f_X(x)$  para todo  $x$ , se tiene que  $\mu_X = E(X) = 0$ , de modo que los momentos centrados y no centrados coinciden. La simetría de  $X$  también implica que los momentos de orden impar son todos nulos, es decir,  $E(X^{2k-1}) = 0$  para todo  $k = 1, 2, \dots$ . Consecuentemente,  $\gamma_X = 0$ .

# Momentos y Funciones generadoras

## Ejemplos

Para los momentos de orden par, se tiene que,

$$\begin{aligned} E(X^{2k}) &= \int_{-1}^0 x^{2k}(1+x)dx + \int_0^1 x^{2k}(1-x)dx \\ &= \int_{-1}^0 x^{2k}dx + \int_{-1}^0 x^{2k+1}dx + \int_0^1 x^{2k}dx - \int_0^1 x^{2k+1}dx \\ &= 2 \int_0^1 y^{2k}dy - 2 \int_0^1 y^{2k+1}dy \quad (y = -x) \\ &= \frac{1}{(k+1)(2k+1)}, \quad k = 1, 2, \dots \end{aligned}$$

Así,  $k = 1 \implies \text{Var}(X) = E(X^2) = 1/6$  y  $k = 2 \implies \kappa_X = 36/15 = 2.4$ .

## Momentos y Funciones generadoras

### Ejemplo 1.3

Sea  $X$  = suma de valores en las caras superiores de dos dados arrojados al azar. Aquí,  $\mathcal{X} = \{2, 3, \dots, 12\}$ , con fmp dada por,

$$f_X(x) = P(X = x) = \begin{cases} \frac{1}{36} \times \min(x - 1, 13 - x), & \text{si } x \in \mathcal{X}, \\ 0, & \text{si no.} \end{cases}$$

Luego,

- i)  $\mu_X = \frac{1}{36} \sum_{x=2}^{12} x \times \min(x - 1, 13 - x) = 7.$
- ii)  $\sigma_X^2 = \frac{1}{36} \sum_{x=2}^{12} (x - 7)^2 \times \min(x - 1, 13 - x) = 5.833$
- iii)  $E\{(X - 7)^3\} = \frac{1}{36} \sum_{x=2}^{12} (x - 7)^3 \times \min(x - 1, 13 - x) = 0.$  Luego  $\gamma_X = 0$ , y la distribución es simétrica.
- iv)  $E\{(X - 7)^4\} = \frac{1}{36} \sum_{x=2}^{12} (x - 7)^4 \times \min(x - 1, 13 - x) = 80.5$  Luego  $\kappa_X = 80.5/2.415^4 = 2.366.$

# Momentos y Funciones generadoras

## Función generadora de momento

La distribución de probabilidades de una variable aleatoria  $X$  también puede ser caracterizada mediante la denominada función generadora de momento (fgm).

La existencia de la fgm determina la existencia de los momentos de la variable aleatoria  $X$ , y como su nombre lo indica, ella genera los momentos de  $X$ .

Aunque en muchos casos puede ser más fácil calcular los momentos directamente de su definición, la utilidad de la fgm no es sólo generar momentos, sino que también ayudar a caracterizar una distribución.

En otras palabras, cada distribución tiene asociada una única fgm (provisto que exista) y viceversa.

# Momentos y Funciones generadoras

## Definición 1.3

**Función generadora de momentos:** Sea  $X$  una variable aleatoria con fda  $F_X$ . La función generadora de momento (fgm) de  $X$  (o  $F_X$ ), denotada por  $M_X(t)$ , se define como,

$$M_X(t) = E(e^{tX}),$$

siempre que exista la esperanza para  $t$  en alguna vecindad de 0. Es decir, existe  $h > 0$  tal que, para todo  $t$  en  $(-h, h)$ ,  $E(e^{tX})$  exista.

Si la esperanza no existe en una vecindad de 0, decimos que la fgm de  $X$  no existe.



## Momentos y Funciones generadoras

Más explícitamente, la fgm de  $X$  se calcula como,

$$M_X(t) = \begin{cases} \sum_x e^{tx} f_X(x) & \text{si } X \text{ es discreta} \\ \int_{-\infty}^{\infty} e^{tx} f_X(x) dx & \text{si } X \text{ es continua} \end{cases}$$

Para ver cómo la fgm genera los momentos de  $X$ , primero note que si  $|t| < h$ , algún  $h > 0$ , entonces,

$$e^{tx} = \sum_{k=0}^{\infty} \frac{t^k}{k!} x^k \quad (\text{converge para todo } x)$$

$$\begin{aligned} \Rightarrow M_X(t) &= E(e^{tX}) = E\left(\sum_{k=0}^{\infty} \frac{t^k}{k!} X^k\right) = \sum_{k=0}^{\infty} \frac{t^k}{k!} E(X^k) \\ &= 1 + \frac{t}{1!} E(X) + \frac{t^2}{2!} E(X^2) + \cdots + \frac{t^k}{k!} E(X^k) + \frac{t^{k+1}}{(k+1)!} E(X^{k+1}) \end{aligned}$$

Dirivando en ambos lados  $k$  veces con respecto a  $t$ , y evaluando en el resultado en  $t = 0$ , se obtiene el siguiente teorema.

# Momentos y Funciones generadoras

## Teorema 1.3

Si  $X$  tiene fgm  $M_X(t)$ , entonces,

$$E(X^k) = M_X^{(k)}(0),$$

donde,

$$M_X^{(k)}(0) = \frac{d^k}{dt^k} M_X(t) |_{t=0}$$

Es decir, el  $k$ -ésimo momento de  $X$  es igual a la  $k$ -ésima derivada de  $M_X(t)$  evaluada en  $t = 0$ .

A continuación, se entrega una demostración alternativa de este resultado.

# Momentos y Funciones generadoras

## Demostración 1.2

Suponiendo que podemos diferenciar bajo el signo integral, tenemos

$$\begin{aligned}\frac{d}{dt}M_X(t) &= \frac{d}{dt} \int_{-\infty}^{\infty} e^{tx} f_X(x) dx \\ &= \int_{-\infty}^{\infty} \left( \frac{d}{dt} e^{tx} \right) f_X(x) dx \\ &= \int_{-\infty}^{\infty} (x e^{tx}) f_X(x) dx \\ &= E(X e^{tX}).\end{aligned}$$

Así,

$$\frac{d}{dt}M_X(t)|_{t=0} = E(X e^{tX}|_{t=0}) = E(X).$$

# Momentos y Funciones generadoras

## Ejemplos

Procediendo de manera análoga, podemos probar que,

$$\frac{d^k}{dt^k} M_X(t)|_{t=0} = E(X^k e^{tX}|_{t=0}) = E(X^k).$$

### Ejemplo 1.4

Sea  $X$  una variable aleatoria con fdp dada por,

$$f_X(x) = \begin{cases} 2e^{-2x} & \text{si } x \geq 0 \\ 0 & \text{eoc} \end{cases}$$

Luego,

$$\begin{aligned} M_X(t) &= \int_0^{\infty} e^{tx} 2e^{-2x} dx \\ &= (1 - t/2)^{-1}, \quad \text{con } t < 2. \end{aligned}$$

# Momentos y Funciones generadoras

## Ejemplo 1.5

Se dice que una variable aleatoria continua  $X$  tiene distribución normal estándar, denotada por  $X \sim N(0, 1)$ , si la fdp  $X$  esta dada por,

$$f_X(x) := \phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad -\infty < x < \infty.$$

Note que  $\phi(-x) = \phi(x) \forall x$ , de modo que la distribución  $N(0, 1)$  es simétrica con respecto al 0; luego, si sus momentos impares existen, todos ellos deben ser nulos. En este caso, para obtener el  $k$ -ésimo momento de  $X$ , hay que resolver la integral,

$$E(X^k) = \int_{-\infty}^{\infty} x^k \phi(x) dx$$

para lo cual hay que integrar por parte en forma recursiva.

## Momentos y Funciones generadoras

En cambio, al notar que  $e^{tx}\phi(x) = e^{t^2/2}\phi(x-t)$ , el cálculo de la fgm de la distribución normal estandar es bastante simple, ya que,

$$\begin{aligned}M_X(t) &= \mathbb{E}(e^{tX}) = \int_{-\infty}^{\infty} e^{tx}\phi(x)dx \\&= \int_{-\infty}^{\infty} e^{t^2/2}\phi(x-t)\phi(x)dx \\&= e^{t^2/2} \int_{-\infty}^{\infty} \phi(y)dy \quad (y = x - t) \\&= e^{t^2/2},\end{aligned}$$

la cual existe para todo  $t \in \mathbb{R}$ . Derivar esta función es bastante simple, como se ilustra a continuación.

## Momentos y Funciones generadoras

Por ejemplo, para la primera y segunda derivada de  $M_X(t) = e^{t^2/2}$ , es decir, de la fgm de  $X \sim N(0, 1)$ , se tiene que,

$$M'_X(t) = tM_X(t) \implies E(X) = M'_X(0) = 0,$$

$$\begin{aligned} M''_X(t) &= (1 + t^2)M_X(t) + tM'_X(t) \implies E(X^2) = M''_X(0) = 1 \\ &\implies \text{Var}(X) = E(X^2) - \{E(X)\}^2 = 1 - 0^2 = 1. \end{aligned}$$

**Tarea:** Verifique que  $\gamma_X = E(X^3) = 0$  (simetría) y  $\kappa_X = E(X^4) = 3$ .

Resumiendo,

$$X \sim N(0, 1) \implies \begin{cases} \mu_X = 0 & (\text{media}), \\ \sigma_X^2 = 1 & (\text{varianza}), \\ \gamma_X = 0 & (\text{asimetría}), \\ \kappa_X = 3 & (\text{curtosis}), \end{cases}$$

## Momentos y Funciones generadoras

### Ejemplo 1.6

Sea  $X$  una variable aleatoria discreta con valores en  $\mathcal{X} = \{x_1, \dots, x_m\}$ . Entonces,

$$M_X(t) = \sum_{i=1}^m e^{tx_i} P(X = x_i).$$

Si  $\mathcal{X} = \{-1, 1\}$ , y  $P(X = -1) = P(X = 1) = \frac{1}{2}$ , entonces,

$$M_X(t) = \frac{1}{2}\{e^{-t} + e^t\},$$

para todo  $t \in \mathbb{R}$ . La media de  $X$  está dada por,

$$EX = \frac{d}{dt} M_X(t)|_{t=0} = \frac{1}{2}\{-e^{-t} + e^t\}|_{t=0} = 0.$$



# Momentos y Funciones generadoras

## Algunas propiedades

No unicidad de los momentos. Dos variables aleatorias,  $X$  e  $Y$  con distintas fdp, pueden tener los mismos momentos, a menos que tengan soporte acotado. Por otro lado, una importante propiedad de la fgm de una variable aleatoria es que, cuando existe, caracteriza la distribución de la variable. El siguiente teorema resume estos resultados.

### Teorema 1.4

Sean  $F_X(x)$  y  $F_Y(y)$  dos fda cuyos momentos existen.

- i) Si  $X$  e  $Y$  tienen soporte acotado, entonces  $F_X(u) = F_Y(u)$  para todo  $u$  si y sólo si  $E(X^r) = E(Y^r)$  para todo  $r = 0, 1, 2, \dots$
- ii) Si la fgm existe y  $M_X(t) = M_Y(t)$  para todo  $t$  en alguna vecindad de 0, entonces  $F_X(u) = F_Y(u)$  para todo  $u$ .

### Demostración 1.3

Ver Casella & Berger (2002).

# Momentos y Funciones generadoras

## Teorema 1.5

Para constantes cualquiera  $a$  y  $b$ , la fgm de la variable aleatoria  $aX + b$  está dada por,

$$M_{aX+b}(t) = e^{bt} M_X(at).$$

## Demostración 1.4

Por definición,

$$\begin{aligned} M_{aX+b}(t) &= \mathbb{E}(e^{(aX+b)t}) = \mathbb{E}(e^{(aX)t} e^{bt}) \\ &= e^{bt} \mathbb{E}(e^{(at)X}) \\ &= e^{bt} M_X(at). \end{aligned}$$

## Momentos y Funciones generadoras

### Ejemplo 1.7

Sabemos que  $X \sim N(0, 1) \iff M_X(t) = e^{t^2/2}$ ,  $t \in \mathbb{R}$ . Entonces, por el Teorema 1.5, la fgm de  $Y = \sigma X + \mu$ , donde  $\sigma > 0$  (parámetro de escala) y  $\mu \in \mathbb{R}$  (parámetro de localización), esta dada por,

$$M_Y(t) = e^{t\mu} e^{t^2\sigma^2/2} = e^{t\mu + t^2\sigma^2/2}, \quad t \in \mathbb{R}.$$

Tal fgm caracteriza la denominada distribución normal con media  $\mu$  y varianza  $\sigma^2$ , denotada por  $Y \sim N(\mu, \sigma^2)$ . Recordando que  $E(X) = 0$  y  $\text{Var}(X) = 1$ , se tiene que

$$E(Y) = \sigma E(X) + \mu = \mu \quad \text{y} \quad \text{Var}(Y) = \sigma^2 \text{Var}(X) = \sigma^2.$$

Además, es posible probar que la fdp de  $Y = \sigma X + \mu$  está dada por

$$f_Y(y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y-\mu)^2/2\sigma^2}, \quad -\infty < y < \infty.$$

# References

- Blanco, L., Arunachalam, V. y Dharmaraja, S. (2012). *Introduction to Probability and Stochastic Processes*. John Wiley, New Jersey.
- Casella, G. y Berger, R.L. (2002). *Statistical Inference*. Second Edition. Duxbury, California.