

EYP 1027 Modelos Probabilísticos

Clase 19

Profesor: Reinaldo B. Arellano-Valle

Departamento de Estadística
Pontificia Universidad Católica de Chile

Segundo Semestre 2020



Contenido I

- 1 Muestras aleatorias y distribuciones muestrales
 - Conceptos básicos
 - La media muestral y la varianza muestral
 - Muestreo desde la distribución normal

Muestras aleatorias y distribuciones muestrales

Conceptos básicos

Como ya sabemos, una distribución de probabilidad, también llamada distribución poblacional (o simplemente población), describe el compartamiento probabilístico de una determinada variable aleatoria.

También sabemos que toda distribución de probabilidad o población puede ser descrita o representada por su fda (F) o bien por su fmp (f) en el caso discreto o fdp (f) en el caso continuo.

Normalmente no es posible conocer toda la población, por lo sólo disponemos de una muestra representativa de dicha población.

A partir de la muestra, podemos inferir sobre características poblacionales, llamadas parámetros, que nos interesa conocer.

Para ello, se requiere saber primero la distribución de probabilidad (exacta o asintótica) de las versiones muestrales de tales características, las cuales son denominadas estadísticos.

Muestras aleatorias y distribuciones muestrales

Definición 1.1

Se dice que X_1, \dots, X_n es una muestra aleatoria de tamaño n (ma(n)) de una población con fmp o fdp f si X_1, \dots, X_n son variables aleatorias mutuamente independientes e idénticamente distribuidas (iid) f

Como es obvio, si X_1, \dots, X_n es una ma(n) de f , entonces la fmp o fdp conjunta de la ma(n) es,

$$f(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i).$$

Cuando la ma(n) proviene de una familia paramétrica $f(x; \theta)$, entonces la fmp o fdp conjunta de X_1, \dots, X_n es,

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

donde el parámetro θ (posiblemente vectorial) etiqueta la fmp o fdp.

Muestras aleatorias y distribuciones muestrales

Ejemplo 1.1

Sea X_1, \dots, X_n una ma(n) de una población $\exp(\lambda)$, donde $\lambda > 0$ es el parámetro asociado. Por ejemplo, X_1, \dots, X_n podrían corresponder a los tiempos de vida (medidos en años y fracciones) de n artefactos electrónicos idénticos, los que se hacen funcionar hasta que fallen. La fdp conjunta de la ma(n) es,

$$\begin{aligned} f(x_1, \dots, x_n; \lambda) &= \prod_{i=1}^n f(x_i; \lambda) \\ &= \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}, \quad x_i > 0, \quad i = 1, \dots, n. \end{aligned}$$

Muestras aleatorias y distribuciones muestrales

Con esta fdp se pueden estudiar diferentes propiedades de la muestra; por ejemplo, para calcular la probabilidad de que todos los artefactos duren más de 2 años,

$$P(X_1 > 2, \dots, X_n > 2) = \prod_{i=1}^n P(X_i > 2) = \exp\{-2n\lambda\}.$$

A partir de la fda conjunta de la $ma(n)$ también se puede demostrar que la variable aleatoria $\sum_{i=1}^n X_i$ tiene distribución $Gama(n, \lambda)$, y por tanto que

$$2\lambda \sum_{i=1}^n X_i \sim \chi_{2n}^2.$$

Este resultado juega un rol importante cuando se desea inferir sobre el verdadero valor del parámetro λ , es decir, aquel valor efectivamente generó la $ma(n)$ observada.

Muestras aleatorias y distribuciones muestrales

Definición 1.2

Sea $T(x_1, \dots, x_n)$ una función de valor real o bien vectorial, y sea X_1, \dots, X_n una ma(n) de una población. Entonces la variable o vector aleatoria(o) $T = T(X_1, \dots, X_n)$ se denomina estadístico. La distribución de probabilidad de un estadístico T se llama distribución muestral de T .

La definición de un estadístico es muy amplia; cualquier función de la ma(n) que no dependa de ningún parámetro desconocido es un estadístico. Por ejemplo, un estadístico puede ser la propia ma(n), el mínimo o el máximo de de la muestra, el promedio de la muestra o alguna medida de la variabilidad de las observaciones de la muestra.

Muestras aleatorias y distribuciones muestrales

La media muestral y la varianza muestral

Habitualmente, los parámetros poblacionales de mayor interés son la media μ y la varianza σ^2 de la población.

Por ende, al disponer de una ma(n) de dicha población, es natural preocuparse de la media \bar{X} y la varianza S^2 de la muestra.

Muestras aleatorias y distribuciones muestrales

Definición 1.3

Dada una muestra aleatoria X_1, \dots, X_n de una población f , dos estadísticos de interés inmediato son:

(a) La media muestral, definida como,

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

(b) La varianza muestral, definida como,

$$S^2 = \frac{(X_1 - \bar{X})^2 + \dots + (X_n - \bar{X})^2}{n - 1} = \frac{1}{n - 1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

También se define la desviación estándar muestral como, $S = \sqrt{S^2}$.

Muestras aleatorias y distribuciones muestrales

Teorema 1.1

Para cualquier secuencia de números reales x_1, \dots, x_n , sea

$\bar{x} = \sum_{i=1}^n x_i/n$. Entonces,

- i) $\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2$ para todo $\mu \in \mathbb{R}$;
- ii) $\min_{\mu \in \mathbb{R}} \sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$, es decir, para $\hat{\mu} = \bar{x}$ la distancia $\sum_{i=1}^n (x_i - \mu)^2$ es mínima;
- iii) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x}) x_i = \sum_{i=1}^n x_i^2 - n\bar{x}^2$.

Tarea: Pruebe que $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

Demostración 1.1

La demostración de ii) es directa de la parte i). Las demostraciones de i) y iii) quedan de ejercicio.

Muestras aleatorias y distribuciones muestrales

Lema 1.1

Sea X_1, \dots, X_n una ma(n) de f , y sea g una función real valorada. Entonces,

- i) $g(X_1), \dots, g(X_n)$ son variables aleatorias iid;
- ii) $E \left\{ \sum_{i=1}^n g(X_i) \right\} = nE \{g(X_1)\}$ provisto que la esperanza exista;
- iii) $\text{Var} \left\{ \sum_{i=1}^n g(X_i) \right\} = n\text{Var} \{g(X_1)\}$ provisto que la varianza exista.

Demostración 1.2

Resultados ya probados en un contexto más general.

Muestras aleatorias y distribuciones muestrales

Teorema 1.2

Sea X_1, \dots, X_n una ma(n) desde una población con media μ y varianza σ^2 finitas. Entonces,

- i) $E(\bar{X}) = \mu$;
- ii) $\text{Var}(\bar{X}) = \sigma^2/n$;
- iii) $E(S^2) = \sigma^2$.

Conclusión: La media muestral \bar{X} y la varianza muestral S^2 de una ma(n) son estimadores insesgados, respectivamente, de la media poblacional μ la varianza poblacional σ^2 .

Muestras aleatorias y distribuciones muestrales

Demostración 1.3

i) y ii) ya fueron probados, por lo que sólo probaremos iii). En efecto, note primero que

$$\begin{aligned} E\{(n-1)S^2\} &= E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) \\ &= \sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \\ &= nEX_1^2 - nE\bar{X}^2 \\ &= n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = (n-1)\sigma^2, \end{aligned}$$

de donde se obtiene el resultado.

Muestras aleatorias y distribuciones muestrales

Teorema 1.3

Sea X_1, \dots, X_n una ma(n) desde una población con fgm $M(t)$.
Entonces la fgm de la media muestral es,

$$M_{\bar{X}}(t) = \{M(t/n)\}^n$$

Demostración 1.4

Tenemos que,

$$M_{\bar{X}}(t) = E\left(e^{t\bar{X}}\right) = E\left(\prod_{i=1}^n e^{tX_i/n}\right) = \prod_{i=1}^n M_{X_i}(t/n) = \{M_X(t/n)\}^n$$

Muestras aleatorias y distribuciones muestrales

El resultado anterior proporciona una forma muy simple para obtener la distribución muestral de \bar{X} cuando $M_{\bar{X}}(t)$ es una fgm conocida, como se ilustra en el siguiente ejemplo.

Ejemplo 1.2

Distribución de la media Sea X_1, \dots, X_n una ma(n) desde una población $N(\mu, \sigma^2)$. Entonces la fgm de la media muestral \bar{X} es,

$$\begin{aligned} M_{\bar{X}}(t) &= \left\{ \exp \left(\mu \frac{t}{n} + \frac{\sigma^2 (t/n)^2}{2} \right) \right\}^n \\ &= \exp \left\{ n \left(\mu \frac{t}{n} + \frac{\sigma^2 (t/n)^2}{2} \right) \right\} = \exp \left\{ \mu t + \frac{(\sigma^2/n) t^2}{2} \right\}. \end{aligned}$$

Así, si la ma(n) proviene de una población $N(\mu, \sigma^2)$, entonces la distribución muestral de \bar{X} es $N(\mu, \sigma^2/n)$.

Muestras aleatorias y distribuciones muestrales

Ejemplo 1.3

Se tiene una máquina de llenado para vaciar 500gr de cereal en una caja de cartón. Suponga que la cantidad de cereal que se coloca en cada caja es una variable aleatoria normalmente distribuida con media 500gr y desviación estándar igual a 20gr.

Para verificar que el peso promedio de cada caja se mantiene en 500gr se toma una muestra aleatoria de 25 de éstas cajas en forma periódica y se pesa el contenido de cada una de ellas.

El gerente de la planta ha decidido detener el proceso y encontrar la falla cada vez que el valor promedio de la muestra sea mayor de 510gr o menor de 490gr. Obtenga la probabilidad de detener el proceso.

Muestras aleatorias y distribuciones muestrales

Sea X_1, X_2, \dots, X_{25} una ma(25), las cuales representan la cantidad de cereal contenido en las cajas de una muestra aleatoria dada.

Por hipótesis $X_i \sim N(500, 20^2)$, $i = 1, 2, \dots, 25$. Luego $\bar{X} \sim N(500, 20^2/25)$.

La probabilidad deseada es igual a uno menos la probabilidad de que \bar{X} se encuentre entre 490 y 510gr.

$$\begin{aligned} P(\text{ Detención del proceso}) &= 1 - P(490 < \bar{X} < 510) \\ &= 1 - P\left(\frac{490 - 500}{4} < Z < \frac{510 - 500}{4}\right) \\ &= 1 - P(-2.5 < Z < 2.5) \\ &= 0.0124. \end{aligned}$$

Muestras aleatorias y distribuciones muestrales

Muestreo desde la distribución normal

Teorema 1.4

Sea X_1, \dots, X_n una ma(n) desde una distribución $N(\mu, \sigma^2)$, y sea $\bar{X} = \sum_{i=1}^n X_i/n$ y $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2/(n-1)$. Entonces,

- i) \bar{X} y S^2 son variables aleatorias independientes;
- ii) \bar{X} tiene una distribución $N(\mu, \sigma^2/n)$;
- iii) $(n-1)S^2/\sigma^2$ distribuye chicuadrado con $n-1$ grados de libertad.

Muestras aleatorias y distribuciones muestrales

Demostración 1.5

Para probar i) note primero que $\sum_{i=1}^n (X_i - \bar{X}) = 0$, de modo que $X_1 - \bar{X} = -\sum_{i=2}^n (X_i - \bar{X})$. Luego,

$$\begin{aligned} S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \left\{ (X_1 - \bar{X})^2 + \sum_{i=2}^n (X_i - \bar{X})^2 \right\} \\ &= \frac{1}{n-1} \left\{ \left(\sum_{i=2}^n (X_i - \bar{X}) \right)^2 + \sum_{i=2}^n (X_i - \bar{X})^2 \right\}. \end{aligned}$$

Muestras aleatorias y distribuciones muestrales

Es decir, S^2 es una función de $(X_2 - \bar{X}, \dots, X_n - \bar{X})$ solamente. Entonces, basta mostrar que estas variables son independientes de \bar{X} .

Suponga (sin pérdida de generalidad) que $\mu = 0$ y $\sigma = 1$. Entonces, la fdp conjunta de la muestra X_1, \dots, X_n , está dada por,

$$f(x_1, \dots, x_n) = (2\pi)^{-n/2} e^{-\sum_{i=1}^n x_i^2/2}, \quad -\infty < x_i < \infty.$$

Considere la transformación uno-a-uno dada por,

$$Y_1 = \bar{X}, \quad Y_2 = X_2 - \bar{X}, \dots, Y_n = X_n - \bar{X}.$$

Esta es una transformación lineal en (X_1, \dots, X_n) con un jacobiano igual a $1/n$.

Muestras aleatorias y distribuciones muestrales

Luego,

$$\begin{aligned} f(y_1, \dots, y_n) &= n(2\pi)^{-n/2} e^{-(y_1 - \sum_{i=2}^n y_i)^2/2} \\ &\times e^{-\sum_{i=2}^n (y_i + y_1)^2/2}, \quad -\infty < y_i < \infty, \quad i = 1, \dots, n, \\ &= (n/(2\pi))^{1/2} e^{(-ny_1^2)/2} \\ &\times n^{1/2} (2\pi)^{-(n-1)/2} e^{-\left\{ \sum_{i=2}^n y_i^2 + (\sum_{i=2}^n y_i)^2 \right\}/2}, \\ &\quad -\infty < y_i < \infty, \quad i = 1, \dots, n. \end{aligned}$$

Dado que la fdp conjunta de Y_1, \dots, Y_n se puede escribir como el producto de las marginales, se deduce que $Y_1 = \bar{X}$ es independiente de $Y_2 = X_2 - \bar{X}, \dots, Y_n = X_n - \bar{X}$ y, por lo tanto, que \bar{X} es independiente de S^2 .

Muestras aleatorias y distribuciones muestrales

Para probar iii), recuerde que

$$\sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2 = \sum_{i=1}^n (X_i - \mu)^2;$$

es decir,

$$(n-1)S^2 + n(\bar{X} - \mu)^2 = \sum_{i=1}^n (X_i - \mu)^2.$$

Al dividir ambos miembros de la expresión anterior por la varianza poblacional σ^2 , se tiene

$$\frac{(n-1)S^2}{\sigma^2} + \frac{n(\bar{X} - \mu)^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$$

o

$$\frac{(n-1)S^2}{\sigma^2} + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 = \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}. \quad (*)$$

Muestras aleatorias y distribuciones muestrales

Pero $(X_i - \mu)/\sigma \stackrel{\text{iid}}{\sim} N(0, 1)$, de modo que $(X_i - \mu)^2/\sigma^2 \stackrel{\text{iid}}{\sim} \chi_1^2$ y, por tanto, $\sum_{i=1}^n (X_i - \mu)^2/\sigma^2 \sim \chi_n^2$.

Similar, como $\bar{X} \sim N(\mu, \sigma^2/n)$, se tiene que $\{(\bar{X} - \mu)/\sigma/\sqrt{n}\}^2 \sim \chi_1^2$.

Pero como fue probado, $(n-1)S^2/\sigma^2$ y $[(\bar{X} - \mu)/\sigma/\sqrt{n}]^2$ son variables aleatorias independientes, entonces, de (*) se concluye que $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$.

Muestras aleatorias y distribuciones muestrales

La distribución t –Student Sean X e Y variables aleatorias independientes tales que $X \sim N(0, 1)$ e $Y \sim \chi^2_{(k)}$. Considere la transformación

$$g(x, y) = \left(x / \sqrt{y/k}, y \right)$$

La transformación inversa está dada por,

$$h(x, y) = (x\sqrt{y/k}, y),$$

mientras que el Jacobiano es,

$$J(x, y) = \sqrt{y/k}.$$

Muestras aleatorias y distribuciones muestrales

Por lo tanto, la fdp conjunta de $Z = X/\sqrt{Y/k}$ y $W = Y$ esta dada por,

$$f_{Z,W}(z, w) = \sqrt{w/k} f_{X,Y} \left(z\sqrt{w/k}, w \right), \quad x \in \mathbb{R}, \quad w > 0,$$

donde,

$$f_{X,Y}(x, y) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \frac{(1/2)^{k/2}}{\Gamma(k/2)} y^{k/2-1} e^{-y/2}, \quad x \in \mathbb{R}, \quad y > 0.$$

Integrando $f_{Z,W}(z, w)$ con respecto a w , se obtiene la fdp marginal de Z , es decir,

$$f_Z(z) = \frac{\Gamma((k+1)/2)}{\sqrt{k\pi}\Gamma(k/2)} \left(1 + \frac{z^2}{k}\right)^{-(k+1)/2}, \quad z \in \mathbb{R},$$

la cual corresponde a la fdp de una distribución t -Student con k grados de libertad.

Notación: $Z \sim t_k$.

Muestras aleatorias y distribuciones muestrales

La distribución F Sean X e Y variables aleatorias independientes tales que $X \sim \chi_m^2$ e $Y \sim \chi_n^2$. Considere la transformación,

$$g(x, y) = \left(\frac{x/m}{y/n}, y \right)$$

La función inversa de g está dada por,

$$h(x, y) = \left(\frac{m}{n}xy, y \right),$$

y tiene un Jacobiano igual a $J(x, y) = \frac{m}{n}y$. Luego, la fdp conjunta de $Z = \frac{nX}{mY}$ y $W = Y$ está dada por,

Muestras aleatorias y distribuciones muestrales

$$f_{Z,W}(z, w) = \frac{(1/2)^{m/2} (1/2)^{n/2}}{\Gamma(m/2) \Gamma(n/2)} \left(\frac{m}{n}zw\right)^{\frac{m}{2}-1} w^{\frac{n}{2}-1} e^{\{-\frac{1}{2}w(\frac{m}{n}z+1)\}}, \\ z > 0, w > 0$$

Integrando con respecto a w encontramos la fdp de Z , dada por la siguiente expresión,

$$f_Z(z) = \frac{\Gamma((m+n)/2)}{\Gamma(m/2) \Gamma(n/2)} \left(\frac{m}{n}\right)^{\frac{m}{2}} z^{\frac{m}{2}-1} \left(1 + \frac{m}{n}z\right)^{-(m+n)/2}, \quad z > 0,$$

la cual corresponde a la fdp de una distribución F con m gl en el numerador y n gl en el denominador.

Notación: $Z \sim F_{m,n}$.

Muestras aleatorias y distribuciones muestrales

Teorema 1.5

Sea X_1, \dots, X_n una ma(n) desde una distribución $N(\mu, \sigma^2)$. Entonces la variable aleatoria $(\bar{X} - \mu)/(S/\sqrt{n})$ tiene una distribución t -Student con $n - 1$ grados de libertad.

Demostración 1.6

Basta notar que $\sqrt{n}(\bar{X} - \mu)/\sigma \sim N(0, 1)$ y que es independiente de $(n - 1)S^2/\sigma^2 \sim \chi_{n-1}^2$.

Luego la variable aleatoria $T = (\bar{X} - \mu)/(S/\sqrt{n}) \sim t_{n-1}$. Además,

$$\begin{aligned} E(T) &= 0, & \text{si } n - 1 > 1 \\ \text{Var}(T) &= \frac{n - 1}{n - 2}, & \text{si } n - 2 > 2 \end{aligned}$$

Muestras aleatorias y distribuciones muestrales

Teorema 1.6

Sea X_1, \dots, X_n una ma(n) de una población $N(\mu_X, \sigma_X^2)$, y sea Y_1, \dots, Y_m una ma(m) una población independiente $N(\mu_Y, \sigma_Y^2)$. La variable aleatoria $F = (S_X^2/\sigma_X^2) / (S_Y^2/\sigma_Y^2)$ tiene una distribución F con $n - 1$ y $m - 1$ grados de libertad.

Demostración 1.7

Notemos que $(n - 1)S_X^2/\sigma_X^2 \sim \chi_{n-1}^2$ y que es independiente de $(m - 1)S_Y^2/\sigma_Y^2 \sim \chi_{m-1}^2$.

Luego la variable aleatoria $F = (S_X^2/\sigma_X^2)/(S_Y^2/\sigma_Y^2)$. Además,

$$E(F) = \frac{m - 1}{m - 3}, \quad \text{si } m - 3 > 1$$

Muestras aleatorias y distribuciones muestrales

Teorema 1.7

- i) Si $X \sim F_{p,q}$, entonces $1/X \sim F_{q,p}$; esto es, el recíproco de una variable aleatoria F también tiene una distribución F .
- ii) Si $X \sim t_q$, entonces $X^2 \sim F_{1,q}$
- iii) Si $X \sim F_{p,q}$, entonces $(p/q)X/(1 + (p/q)X) \sim \text{Beta}(p/2, q/2)$.

Problema: Qué hacemos si no tenemos normalidad?

References

- Blanco, L., Arunachalam, V. y Dharmaraja, S. (2012). *Introduction to Probability and Stochastic Processes*. John Wiley, New Jersey.
- Casella, G. y Berger, R.L. (2002). *Statistical Inference*. Second Edition. Duxbury, California.
- DeGroot, M. y Schervish, M.J. (2012). *Probability and statistics*. Fourth Edition. Addison-Wesley, New York.