



Ayudantía 11

Exemplar SVM y Reinforcement Learning (RL)

Por Benjamín Santander y Nicolás San Martín



SVM Tradicional

Realizamos separaciones por conjuntos de datos para cada categoría


Visual Object Detection





Exemplar SVM

Tomamos un ejemplo de esa categoría y lo enfrentamos a todos los demás valores



Como distintos modelos clasifican un objeto.






Ventajas y Desventajas

Aspecto	SVM Tradicional	Exemplar SVM
Objetivo	Clasificación general	Detección / búsqueda por ejemplo
Modelo	Un único clasificador	Un clasificador por ejemplo positivo
Generalización	Buena con datos balanceados	Limitada al ejemplo específico
Requiere muchos positivos	Sí	No (funciona con pocos o uno)
Costo computacional	Bajo a moderado	Alto (muchos modelos a entrenar)
Escalabilidad	Buena	Mala (no escala bien con muchos ejemplos)
Uso típico	Clasificación, reconocimiento de patrones	Recuperación visual, detección de objetos



¿Qué es?

Aprender a elegir acciones en un entorno tal que se maximice la **recompensa esperada**





¿Y el entorno?



Markov Decision Process (MDP)

$$\mathcal{M} = \langle S, A, p, \gamma \rangle$$

S → Conjunto de estados

$A(s)$ → Conjunto de acciones

$p(s', r \mid s, a)$ → Función de dinámica del entorno


γ → Factor de descuento



Markov Decision Process (MDP)

Para aplicar reinforcement learning, realizamos un supuesto:

Propiedad Markoviana $\rightarrow$ $\mathbf{s}'$ y $\mathbf{r}$ dependen **únicamente** de $\mathbf{s}$ y $\mathbf{a}$





Política de comportamiento (π)

El agente tiene como objetivo encontrar una política de comportamiento que le indique qué acción debe tomar en un instante determinado de un estado s_t

$$\pi_{\theta}(\mathbf{a}_t | \mathbf{s}_t)$$

Donde el objetivo es encontrar política una **maximice** la recompensa esperada



Value function

La *value function* es una estimación del retorno esperado que el agente puede obtener desde un cierto estado si sigue una política π

$$V^*(s) = \max_{\pi} \mathbb{E} \left[\sum_{t=0}^H \gamma^t R(s_t, a_t, s_{t+1}) \mid \pi, s_0 = s \right]$$

Función de valor del agente al iniciar en un estado s y seguir la política π


Tasa de descuento para recompensas más lejanas en el tiempo

Recompensa del agente en el instante de t al seguir la política π



Ejemplos solucionables con RL

Reinforcement Learning Lunar Lander CartPole (Pole Balancing)



UArizona DataLab. (2024, 14 marzo). *Reinforcement Learning Lunar Lander*

[Video]. YouTube. <https://www.youtube.com/watch?v=nQxmDH3mdCY>



PilcoLearner. (2011, 26 mayo). *Cart-Pole swing-up* [Video]. YouTube.

<https://www.youtube.com/watch?v=XiigTGKZfks>