

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Árboles de decisión

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación

Recapitulemos un poco lo que hemos visto hasta ahora en el curso

- Discutimos sobre la programación directa vs aprendizaje para resolver problemas computacionalmente
- Continuamos con la relación íntima entre ML y datos, desde el punto de vista del aprendizaje inductivo.
- Luego, vimos los conceptos fundamentales de ML, generalización y representación de datos.
- Ahora comenzaremos con la revisión de modelos y algoritmos de aprendizaje supervisado.

El set de datos **MNIST** permite construir **clasificadores de dígitos** a partir de imágenes (OCR)



- MNIST es un set de datos compuesto de imágenes de dígitos escritos a mano.
- Cada imagen muestra un sólo dígito entre 0 y 9. Las imágenes son binarias con una resolución de $28 \times 28 = 784$ píxeles.
- El dataset consta de 60.000 ejemplos de entrenamiento y 10.000 de test.

El set de datos **MNIST** permite construir **clasificadores de dígitos** a partir de imágenes (OCR)




- ¿Cómo podríamos resolver este problema (clasificación de dígitos)?
- Quizá, visualizar el espacio de características nos da una pista.

¿Es posible **visualizar** directamente el espacio de características de MNIST?


NO

¿Por qué?

Usando técnicas **no supervisadas** de reducción de dimensionalidad, como PCA o tSNE, es posible **transformar** el espacio de características y hacerlo visualizable




Usando técnicas **no supervisadas** de reducción de dimensionalidad, como PCA o tSNE, es posible **transformar** el espacio de características y hacerlo visualizable



¿Cómo podríamos resolver este problema?
(aka cuál es el algoritmo más simple que podríamos usar)

Clasificador de **k-vecinos más cercanos** permite enfrentar este tipo de problema de manera intuitiva

- Entrenamiento consiste únicamente en almacenar los datos de entrenamiento.
- La inferencia sobre un nuevo ejemplo se basa directamente en un voto de mayoría sobre la clase de los k ejemplos más cercanos (similares).
- Supuestos muy fuertes: ejemplos de la misma clase son cercanos (espacio de características semántico) o métrica de distancia especializada (semántica).
- **Funcionamiento complejo cuando el espacio de características no es numérico continuo.**





Dadas las limitaciones del esquema de k-vecinos cercanos, ¿cómo solucionamos este nuevo problema de **clasificación**?

Clima	Temperatura	Humedad	Viento	Jugar?
soleado	alta	alta	F	No
soleado	alta	alta	V	No
nublado	alta	alta	F	Si
lluvioso	Agradable	alta	F	Si
lluvioso	frio	normal	F	Si
lluvioso	frio	normal	V	No
nublado	frio	normal	V	Si
soleado	Agradable	alta	F	No
soleado	frio	normal	F	Si
lluvioso	Agradable	normal	F	Si
soleado	Agradable	normal	V	Si
nublado	Agradable	alta	V	Si
nublado	alta	normal	F	Si
lluvioso	Agradable	alta	V	No


Dadas las limitaciones del esquema de k-vecinos cercanos, ¿cómo solucionamos este nuevo problema de **clasificación**?

Clima	Temperatura	Humedad	Viento	Jugar?
soleado	alta	alta	F	No
soleado	alta	alta	V	No
nublado	alta	alta	F	Si
lluvioso	Agradable	alta	F	Si
lluvioso	frio	normal	F	Si
lluvioso	frio	normal	V	No
nublado	frio	normal	V	Si
soleado	Agradable	alta	F	No
soleado	frio	normal	F	Si
lluvioso	Agradable	normal	F	Si
soleado	Agradable	normal	V	Si
nublado	Agradable	alta	V	Si
nublado	alta	normal	F	Si
lluvioso	Agradable	alta	V	No




Árboles de decisión pueden solucionar el caso anterior

- Técnica de aprendizaje supervisado.
- Pueden realizar clasificación y regresión.
- Pueden usarse sobre distintos tipos de *features* (binaria, categórica, numérica, etc).






Árboles de decisión son ampliamente utilizados en la práctica


- Cada nodo interno representa una característica/atributo y cada nodo hoja representa una categoría.
- En cada nodo interno, se realiza un test en base a los valores de la característica.
- Aristas representan el resultado del test.
- Para clasificar un registro, se debe pasar desde la raíz hasta alguna hoja.



Los árboles de decisión pueden “verse” de múltiples maneras




¿Cómo construimos un árbol de decisión?





Podemos usar un algoritmo recursivo para construir un árbol

1. ¿Pertenece todos los registros a la misma clase?
 - Retornar marcando el nodo hoja con la clase respectiva.
2. ¿Tienen todos los registros el mismo valor para todas las características?
 - Retornar marcando nodo hoja con la clase más común.
3. De lo contrario:
 - i. Seleccionar la mejor característica.
 - ii. Usar esta característica como nodo raíz.
 - iii. Dividir el set de entrenamiento restante de acuerdo a este atributo y para cada rama resultante continuar la construcción del árbol en forma recursiva.




La elección de la mejor característica depende de la tarea que busquemos solucionar


- Si objetivo es clasificar, es razonable que la **mejor característica** sea aquella que mejor separe las clases.
- Dos maneras típicas de medir esto son:
 - Gini Index: desigualdad (inequidad) sobre distintas categorías.
 - **Information Entropy**: uniformidad de una distribución o cantidad de información necesaria para codificar la ocurrencia de eventos.




Entropía permite capturar de manera
eficiente cuán informativa es una distribución



High Knowledge
Low Entropy



Medium Knowledge
Medium Entropy




Low Knowledge
High Entropy

Entropía permite capturar de manera eficiente cuán informativa es una distribución

- “Intuitivamente”, la entropía puede verse como un promedio ponderado de la información sobre los eventos particulares:

$$H(S) = - \sum_{c_i} p_i \log_2 p_i$$




$$f(x) = -x \log_2(x)$$

Entropía permite capturar de manera eficiente cuán informativa es una distribución

- “Intuitivamente”, la entropía puede verse como un promedio ponderado de la información sobre los eventos particulares:

$$H(S) = - \sum_{c_i} p_i \log_2 p_i$$


- Por ejemplo:
 - 4 clases (A,B,C,D): 10 registros clase A, 20 clase B, 30 clase C, 40 clase D.
 - Entropía = $-[(.1 \log .1) + (.2 \log .2) + (.3 \log .3) + (.4 \log .4)] = 1.85$ bits.



$$f(x) = -x \log_2(x)$$

¿Cómo nos ayuda entonces la **entropía** a elegir la **mejor característica**?



- Cada valor/umbral de una **feature** genera una partición distinta.
- Cada una de estas particiones tendrá su propia entropía.
- Ahora sí, **intuitivamente**, algo como la media ponderada de la entropía de las particiones generadas podría indicar cuán buena o mala es una característica.
- Esta idea es formalizada a través de una métrica llamada **Ganancia de Información** (Information Gain).



$$InfoGain(D, F) = Entropy(D) - \sum_{v \in Values(F)} \frac{|S_v|}{|S|} Entropy(S_v)$$

Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)

$$InfoGain(D, F) = Entropy(D) - \sum_{v \in Values(F)} \frac{|S_v|}{|S|} Entropy(S_v)$$







Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)


Day	Outlook	Temperature	Humidity	Wind	PlayTenn
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)


Day	Outlook	Temperature	Humidity	Wind	PlayTenn
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No



Elegimos la característica que entrega la mayor ganancia de información (mayor reducción de entropía)




Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)




Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)


Gain(S, Outlook)=0.266




Gain(S, Temp.)=0.029



Gain(S, Humidity)=0.151




Gain(S, Windy)=0.048




Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)

Day	Outlook	Temperature	Humidity	Wind	PlayTenn
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No




¿Cuál atributo?


Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)



Gain(S,Temp.)=?




Gain(humid.,Temp.)=?



Gain(S,Windy)=?


Elegimos la característica que entrega la mayor **ganancia de información** (mayor reducción de entropía)



Algunos detalles prácticos restantes de los árboles de decisión:


¿Cómo encontrar umbrales de Split adecuados para variables numéricas?

- Fuerza bruta
- Ordenar por dimensión, y evaluar split en cada cambio de categoría.



Algunos detalles prácticos restantes de los árboles de decisión: ¿Qué hacemos si la tarea a resolver no es de clasificación?

- Si objetivo es una regresión, es razonable que el **mejor atributo** sea el que **más disminuya el error en la estimación**.
- Cada nodo hoja retorna la media de los ejemplos que contiene.
- En vez de medir IG, se calcula la disminución de la varianza (VR).
- Construcción recursiva sigue la misma idea que para clasificación.



Volvamos un poco a overfitting (sobreajuste) y complejidad


¿Qué tipo de árboles **prefiere** construir el algoritmo que analizamos?
(sesgo inductivo del algoritmo)

Árboles pocos profundos (mientras más arriba aumenta la información, mejor)

¿Tiene esto algo que ver con el sobreajuste?

Occam's Razor¹ (o la navaja de Occam, claramente una traducción poco afortunada) be my guide

*En igualdad de condiciones,
la **explicación** más sencilla
suele ser la más probable ²*




¹ Supuestamente fue enunciado mientras se afeitaba.

² Esto es un principio filosófico/metodológico, no una ley de la naturaleza.

La navaja de Occam es suficientemente general para usarse en casi todo


- “**Numquam ponenda est pluralitas sine necessitate**” -> “La pluralidad nunca debe imponerse sin necesidad” o “Las entidades no deben ser multiplicadas sin necesidad”
- Llevado a un lenguaje moderno, la idea de Occam era que, al enfrentar hipótesis en competencia sobre un fenómeno, debemos preferir la más simple que sea consistente con la evidencia disponible (un golpe al mentón de los conspiranoicos).
- Aterrizado a nuestro contexto de ML, el principio se refiere a lo complejo de las hipótesis (**modelos**) que son consistentes con la evidencia (**con buen rendimiento**).
- Si bien existen definiciones teóricas, operacionalmente la complejidad suele correlacionarse con la cantidad de parámetros entrenables de un modelo.



Sobreajuste es un problema importante para los **árboles de decisión**

Existen varias técnicas que pueden ayudar reduciendo el sobreajuste.

- Detener construcción del árbol en base a un set de validación.
- Detener construcción cuando registros restantes no son estadísticamente significativos.
- Construir un árbol completo y luego podar ramas.
- Penalizar complejidad en métrica de selección del siguiente atributo.



Cuáles son los conceptos centrales de la clase de hoy

- Árboles son técnicas muy eficientes, pero con gran riesgo de sobreajuste.
- Simpleza en la explicación es uno de los criterios principales para evaluar soluciones a problemas de clasificación/regresión.
- Pueden ser muy útiles como primera solución a un problema, si se tienen features de tipos distintos, donde no es evidente como combinarlas.

Ejemplos de código disponibles en Canvas

- Clasificación de dígitos con kNN
- Árboles de decisión desde cero
- Regresión con árboles de decisión
- Sobreajuste y validación cruzada en árboles de decisión



Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Árboles de decisión

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación