

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación




IIC2613 - Inteligencia Artificial

Control de agentes basado en aprendizaje

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación







FLOW


<https://www.youtube.com/watch?v=P7xx9uH2i7w>


El **aprendizaje reforzado** se centra en el estudio de agentes autónomos capaces de aprender a tomar decisiones.

- El agente aprende interactuando con el entorno y recibiendo recompensas (o penalizaciones).
- Las recompensas pueden ser diferidas, se optimiza el retorno acumulado a largo plazo.
- Se debe balancear exploración de acciones nuevas y explotación del conocimiento actual.
- Útil cuando el entorno es complejo o desconocido y no se puede modelar fácilmente.









Datos etiquetados e i.i.d.


Datos no son i.i.d.: el pasado influencia el futuro
No tenemos etiquetas, solo sabemos si tuvimos éxito o no (o si recibimos una recompensa)




- Acciones: ?
- Observaciones del entorno: ?
- Recompensa: ?



- Acciones: movimientos musculares
- Observaciones del entorno: vista, olfato, tacto, oído, gusto
- Recompensa: comida al lograr el objetivo



- Acciones: ?
- Observaciones del entorno: ?
- Recompensa: ?



- Acciones: qué recomendar al usuario
- Observaciones del entorno: elecciones del usuario (historial)
- Recompensa: feedback o elección del usuario (o nada!!)




- Acciones: ?
- Observaciones del entorno: ?
- Recompensa: ?



- Acciones: qué y cuánto comprar
- Observaciones del entorno: niveles de inventario
- Recompensa: ganancia


Antes de empezar con las técnicas, un poco de notación




$\mathbf{s}_t$ – state

$\mathbf{a}_t$ – action

$\pi_\theta(\mathbf{a}_t | \mathbf{s}_t)$ – policy



Antes de empezar con las técnicas, un poco de notación




$\mathbf{s}_t$ – state

$\mathbf{o}_t$ – observation


$\mathbf{a}_t$ – action

$\pi_{\theta}(\mathbf{a}_t | \mathbf{o}_t)$ – policy

$\pi_{\theta}(\mathbf{a}_t | \mathbf{s}_t)$ – policy (fully observed)



La recompensa actúa como una especie de supervisión



which action is better or worse?



$r(\mathbf{s}, \mathbf{a}, \mathbf{s}')$: reward function $\longrightarrow$ tells us which states and actions are better

high reward



low reward

$S, A, r(s, a, s')$ y $p(s' | s, a)$ definen un proceso de decisión markoviano (MDP)

 $\pi:$ 

$$\max_{\pi} \mathbb{E}[\sum_{t=0}^H \gamma^t R(S_t, A_t, S_{t+1}) | \pi]$$

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Control de agentes basado en aprendizaje

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación