

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación




IIC2613 - Inteligencia Artificial

Value Iteration

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación


Recordemos un poco la notación




$\mathbf{s}_t$ – state

$\mathbf{a}_t$ – action

$\pi_\theta(\mathbf{a}_t | \mathbf{s}_t)$ – policy



Recordemos un poco la notación




$\mathbf{s}_t$ – state

$\mathbf{o}_t$ – observation


$\mathbf{a}_t$ – action

$\pi_{\theta}(\mathbf{a}_t | \mathbf{o}_t)$ – policy

$\pi_{\theta}(\mathbf{a}_t | \mathbf{s}_t)$ – policy (fully observed)



La recompensa actúa como una especie de supervisión



which action is better or worse?


$r(\mathbf{s}, \mathbf{a}, \mathbf{s}')$: reward function $\longrightarrow$ tells us which states and actions are better

high reward




low reward

$S, A, r(s, a, s')$ y $p(s' | s, a)$ definen un proceso de decisión markoviano (MDP)



π :



$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^H \gamma^t R(S_t, A_t, S_{t+1}) | \pi \right]$$


Comencemos enfrentando esto de manera intuitiva



La idea de “buenos estados” se puede formalizar a través de la **función de valor**

$V^*(s)$ = suma de las recompensas con descuento al empezar en el estado s y actuar óptimamente

$$V^*(s) = \max_{\pi} \mathbb{E} \left[\sum_{t=0}^H \gamma^t R(s_t, a_t, s_{t+1}) \mid \pi, s_0 = s \right]$$



Supongamos acciones siempre exitosas, $\gamma = 1, H = 100$

$V^*(4,3) =$

$V^*(3,3) =$

$V^*(2,3) =$


$V^*(1,1) =$

$V^*(4,2) =$

La idea de “buenos estados” se puede formalizar a través de la **función de valor**

$V^*(s)$ = suma de las recompensas con descuento al empezar en el estado s y actuar óptimamente

$$V^*(s) = \max_{\pi} \mathbb{E} \left[\sum_{t=0}^H \gamma^t R(s_t, a_t, s_{t+1}) \mid \pi, s_0 = s \right]$$



Supongamos acciones siempre exitosas, $\gamma = 0,9$, $H = 100$

$V^*(4,3) =$

$V^*(3,3) =$

$V^*(2,3) =$


$V^*(1,1) =$

$V^*(4,2) =$

La idea de “buenos estados” se puede formalizar a través de la **función de valor**

$V^*(s)$ = suma de las recompensas con descuento al empezar en el estado s y actuar óptimamente

$$V^*(s) = \max_{\pi} \mathbb{E} \left[\sum_{t=0}^H \gamma^t R(s_t, a_t, s_{t+1}) \mid \pi, s_0 = s \right]$$



Supongamos acciones con $P = 0,8$, $\gamma = 0,9$, $H = 100$

$V^*(4,3) =$

$V^*(3,3) =$

$V^*(2,3) =$

$V^*(1,1) =$

$V^*(4,2) =$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

- $V_0^*(s) = 0 \quad \forall s$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

- $V_0^*(s) = 0 \quad \forall s$

$V_1^*(s)$ = optimal value for state s when $H=1$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

- $V_0^*(s) = 0 \quad \forall s$

$V_1^*(s)$ = optimal value for state s when $H=1$

- $V_1^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_0^*(s'))$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

- $V_0^*(s) = 0 \quad \forall s$

$V_1^*(s)$ = optimal value for state s when $H=1$

- $V_1^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_0^*(s'))$

$V_2^*(s)$ = optimal value for state s when $H=2$

- $V_2^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_1^*(s'))$

¿Cómo podemos estimar esta función de valor?

$V_0^*(s)$ = optimal value for state s when $H=0$

- $V_0^*(s) = 0 \quad \forall s$

$V_1^*(s)$ = optimal value for state s when $H=1$

- $V_1^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_0^*(s'))$

$V_2^*(s)$ = optimal value for state s when $H=2$

- $V_2^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_1^*(s'))$

$V_k^*(s)$ = optimal value for state s when $H = k$

- $V_k^*(s) = \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_{k-1}^*(s'))$

Este simple algoritmo es conocido como *Value Iteration*

Start with $V_0^*(s) = 0$ for all s .

For $k = 1, \dots, H$:

For all states s in S :

$$V_k^*(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_{k-1}^*(s'))$$

$$\pi_k^*(s) \leftarrow \arg \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_{k-1}^*(s'))$$


Es posible demostrar que este algoritmo converge a la función de valor óptima $V^*(s)$, la cual satisface las ecuaciones de Bellman:

$$\Rightarrow \forall s \in S : \quad V^*(s) = \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^*(s')]$$

Veamos gráficamente un ejemplo de su ejecución

$$V_0(s) \leftarrow 0$$

$k = 0$



0.00	0.00	0.00	0.00
0.00		0.00	0.00
0.00	0.00	0.00	0.00


VALUES AFTER 0 ITERATIONS

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_1(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_0(s'))$$

k = 0




k = 0			
0.00	0.00	0.00	0.00
0.00		0.00	0.00
0.00	0.00	0.00	0.00
VALUES AFTER 0 ITERATIONS			

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_2(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_1(s'))$$

k = 1



k = 1			
0.00	0.00	0.00	1.00
0.00		0.00	-1.00
0.00	0.00	0.00	0.00
VALUES AFTER 1 ITERATIONS			

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_2(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_1(s'))$$

k = 2

0.00	0.00	0.72	1.00
0.00		0.00	-1.00
0.00	0.00	0.00	0.00

VALUES AFTER 2 ITERATIONS

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s'|s, a)(R(s, a, s') + \gamma V_k(s'))$$

k = 3

0.00	0.52	0.78	1.00
0.00		0.43	-1.00
0.00	0.00	0.00	0.00

VALUES AFTER 3 ITERATIONS

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_k(s'))$$

k = 4

0.37	0.66	0.83	1.00
0.00		0.51	-1.00
0.00	0.00	0.31	0.00

VALUES AFTER 4 ITERATIONS

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_k(s'))$$

k = 5

0.51	0.72	0.84	1.00
0.27		0.55	-1.00
0.00	0.22	0.37	0.13

VALUES AFTER 5 ITERATIONS

Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_k(s'))$$

k = 12



Noise = 0.2
Discount = 0.9

Veamos gráficamente un ejemplo de su ejecución


$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) (R(s, a, s') + \gamma V_k(s'))$$

k = 100



Noise = 0.2
Discount = 0.9

Al cierre, un ejercicio: términos pareados



- a) Preferir la salida más cercana (+1), pasando cerca del abismo (-10)
- b) Preferir la salida más cercana (+1), evitando completamente el abismo (-10)
- c) Preferir la salida más lejana (+10), pasando cerca del abismo (-10)
- d) Preferir la salida más lejana (+10), evitando completamente el abismo (-10)

1) $\gamma = 0.1, p(error) = 0.5$

2) $\gamma = 0.99, p(error) = 0$

3) $\gamma = 0.99, p(error) = 0.5$

4) $\gamma = 0.1, p(error) = 0$

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Value Iteration

Hans Löbel

Dpto. Ingeniería de Transporte y Logística
Dpto. Ciencia de la Computación