

Clase 20 — Testing con Usuarios

IIC2182 – Interfaces y Experiencia de Usuario



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Primer Semestre 2026

¿Qué veremos hoy?



¿Por qué evaluar?

Por qué observamos a usuarios reales



Redefiniendo la usabilidad

ISO 9241-11 y el modelo de las 5 E



Diseñar la prueba

El esquema Why · What · How · Who



Medición de resultados

Performance, percepción e issues



IA en testing (2025)

Usuarios sintéticos: promesa y límites



Un proceso cíclico

El testing nos devuelve al diseño

¿Qué veremos hoy?



¿Por qué evaluar?

Por qué observamos a usuarios reales



Redefiniendo la usabilidad

ISO 9241-11 y el modelo de las 5 E

¿Por qué evaluar?



La única forma de saber

El esquema Why · What · How · Who



Si no lo ves, nadie lo usará

Performance, percepción e issues



IA en testing (2025)

Usuarios sintéticos: promesa y límites



Un proceso cíclico

El testing nos devuelve al diseño


Recordemos: el Proceso de Diseño

Ya recorrimos casi todo el ciclo

- 1 Empatizar
- 2 Definir
- 3 Idear
- 4 Prototipar
- 5 **Testear con usuarios** ← estamos aquí



Diseñamos basándonos en supuestos. Hoy toca **ponerlos a prueba** con personas reales.



¿Qué es testing con usuarios?

Evaluar un producto observando a personas reales intentar completar tareas con él

“ Usability Testing

Observar a *participantes representativos* mientras realizan *tareas realistas*, y preguntarles por su experiencia — para detectar problemas y oportunidades de mejora.



Personas reales

No tu equipo, no stakeholders: usuarios representativos



Tareas reales

Cosas concretas que harían en el mundo real



Observación

Miramos qué hacen, no solo qué dicen

"You are not your user"

Conoces tu producto demasiado bien. Sabes dónde está cada botón y por qué tomaste cada decisión.



Tu intuición de experto está **sesgada por el conocimiento**. Testear con usuarios reemplaza el "yo creo que..." por el "yo vi que...".

Por qué evaluar con usuarios

✓ Lo que ganas

- Encuentras problemas antes de programarlos
- Resuelves debates de opinión con evidencia
- Descubres cómo piensa el usuario, no cómo crees que piensa
- Arreglar en diseño cuesta una fracción de arreglar en producción

⚠ Lo que evitas

- Lanzar features que nadie entiende
- Discusiones interminables sin datos
- Asumir que "es obvio" cuando no lo es
- Rediseños caros después del lanzamiento



El costo de arreglar un problema crece **~10x en cada fase** del desarrollo. Evaluar temprano es barato.

Definiendo la usabilidad

Antes de medir algo, hay que definir bien qué es

Usabilidad — la definición ISO

“ ISO 9241-11

La *efectividad*, *eficiencia* y *satisfacción* con que un conjunto específico de usuarios logra un conjunto específico de tareas en un entorno particular.



Efectividad

¿Logran la tarea de forma completa y exacta?



Eficiencia

¿Con cuánto esfuerzo y tiempo?



Satisfacción

¿Qué tan agradable fue la experiencia?



Podemos detallar esta definición un poco más...

El modelo de las 5 E

Quesenbery, 2003 — Dimensions of Usability

Efectivo

Qué tan completa y exactamente se logra el trabajo o se alcanzan las metas

Eficiente

Qué tan rápido se completa ese trabajo

Atractivo

Qué tan placentera y satisfactoria resulta la interacción

Tolerante a errores

Qué tan bien previene errores y ayuda a recuperarse de ellos

Fácil de aprender

Qué tan bien apoya el aprendizaje inicial y el continuo

Las 5 E pesan distinto según el producto

El contexto decide qué dimensiones priorizar al evaluar



Sitio de un museo

Prima ser atractivo y fácil de aprender: invitar a explorar.

Un error puntual importa poco.



Formulario de registro

Prima ser eficiente y tolerante a errores: completar sin frustración.

Lo "atractivo" pasa a segundo plano.



No se evalúa "la usabilidad" en abstracto: se decide **qué E importa más** para este producto y este usuario.

Diseñar la prueba



Why

Metas



What

Alcance, tareas, escenarios



How

Enfoque, métricas



Who

Subgrupos, equipo



Definir las cuatro dimensiones produce, al final, un **plan de testing**.

Why · El porqué

Las metas del testing

Formular las metas como preguntas

Metas distintas producen diseños de test completamente distintos



Pregunta comparativa

"¿Nuestra solución mejora significativamente la accesibilidad para adultos mayores frente al diseño anterior?"

→ Apunta a un test comparativo con adultos mayores.



Pregunta de nivel

"¿Qué tan usable consideran los usuarios nuestra solución?"

→ Apunta a un estudio con métricas estándar.



Define **3–5 preguntas** concretas que el test debe responder. Cada tarea existirá para responder una de ellas.

Toda meta especifica dos cosas

Resultado esperado

Cómo se espera que el diseño se desempeñe.

Ej: mejor accesibilidad, menor tasa de error.



Base de comparación

Contra qué se mide ese resultado.

Ej: un diseño anterior, guías establecidas, o un puntaje mínimo en un test estandarizado.

What · El qué

Alcance, tareas y escenarios

Alcance: ¿qué parte del sistema testeamos?

Dos formas de recortar un sistema que aún no está completo

Prototipo horizontal

Ancho y superficial: muchas funciones, pero ninguna a fondo.

Sirve para evaluar impresiones iniciales y navegación general.

Prototipo vertical

Angosto y profundo: pocas funciones, pero completas.

Sirve para evaluar una funcionalidad específica en detalle.



El alcance depende de la meta: ¿quieres una impresión **general** o probar **un flujo concreto**?

Preguntas, tareas y escenarios

Tres piezas que traducen las metas en algo que el usuario hará

Pregunta

La expectativa concreta a verificar.

"¿Logrará el usuario completar la transferencia?"

Tarea

La secuencia de acciones que el usuario realiza para lograr la meta.

"Enviar \$50 a un contacto."

Escenario

Una breve historia que da contexto y motivación a la tarea.

"Tu amigo te pidió que le devuelvas una plata..."

Tareas específicas vs exploratorias



Específicas

Tienen respuesta correcta/incorrecta. Miden si se logra algo concreto.

"Envía \$50 a un contacto de tu lista."



Exploratorias

Abiertas, sin respuesta única. Revelan cómo descubren o exploran.

"Explora la app y cuéntame qué crees que puedes hacer."



A continuación: **3 reglas** de NN/g para escribir tareas que no sesguen al usuario.

Regla 1 · Haz la tarea realista

Pídele algo que de verdad haría — dale libertad de decidir según sus criterios

❌ Mala ✕

"Compra un par de zapatillas Nike running naranjas."

Le impones criterios que no son suyos: solo intentará "cumplir".

✅ Mejor ✓

"Compra un par de zapatillas por menos de \$40."

El usuario compara y elige como lo haría en la vida real.



Alternativa: deja que el participante **defina su propia tarea** (ej. recluta a alguien que justo está comprando algo y déjalo seguir su búsqueda).

Regla 2 · Haz la tarea accionable

Pide que haga la acción, no que la describa

❌ Mala ✕

"Quieres ver una película el domingo. Entra a cinehoyts.cl y dime dónde harías clic."

Responderá con palabras, no con acciones.

✅ Mejor ✓

"Usa cinehoyts.cl para encontrar una película que te gustaría ver el domingo."

Ahora observas la facilidad o frustración reales.



Los datos auto-reportados **no son tan fiables** como ver a la persona usar el sistema de verdad.

Regla 3 · No des pistas ni describas los pasos

Las palabras de la interfaz dentro de la tarea sesgan al usuario

❌ Mala ✕

"Entra, inicia sesión y dime dónde harías clic para ver tu certificado de notas."

Le dictas los pasos y usas las etiquetas del menú.

✅ Mejor ✓

"Averigua los resultados de tu examen de mitad de semestre."

Describe la meta, no el camino.

💡 No uses palabras de los botones: en vez de "suscríbete al *newsletter*", di "encuentra una forma de recibir novedades en tu correo".

💡 Evitar pistas **no es ser vago**: "agenda hora el martes 10am con tu dentista, Dra. Pérez" sigue siendo concreto.

Ordenar varios escenarios

El orden en que presentas las tareas también importa

Impresiones iniciales



Tareas específicas



De general a específico

Empieza por lo amplio, baja al detalle

De simple a complejo

Construye confianza antes de complicar



De corto a largo

Tareas breves primero, luego las extensas



¿Todas juntas o una a una?

Según la meta del test

How · El cómo

El enfoque del test y cómo recogemos datos

Cualitativo vs Cuantitativo

El eje base: ¿quieres entender o quieres medir?

Cualitativo · el porqué

Observas comportamiento para descubrir qué falla y por qué.

Pocas personas (5–8) · observaciones, citas, frustraciones.

Cuantitativo · el cuánto

Recoges números para medir cuán grave o frecuente es algo.

Muchas personas (20–40+) · tasas, tiempos, puntajes.

 La mayoría de los proyectos parten **cualitativos**: con pocas personas ya descubres los problemas grandes.

Contextos: laboratorio vs campo



Laboratorio

Sala montada para capturar comportamiento: grabación de pantalla, video, eye tracking.

El equipo observa y analiza la sesión.



Campo · Guerrilla

Espacio público (un café), recluta gente que pasa a cambio de un incentivo pequeño.

Bajo costo, sorprendentemente revelador.



Campo · Remoto

Prototipo o producto probado por internet. Recluta de cualquier lugar.

El estándar desde 2020.

Remoto: moderado vs no moderado



Moderado

Un facilitador acompaña en tiempo real, observa y repregunta.

+ Insights profundos · - Lento, pocos participantes



No moderado

El usuario hace las tareas solo; una plataforma graba pantalla y voz (ej. A/B).

+ Rápido y a escala · - No puedes repreguntar



Combíñalos: **no moderado** para detectar patrones a escala, luego **moderado** para entender el porqué.

El método estrella: think-aloud

El usuario dice en voz alta lo que piensa, ve y espera

Cómo funciona

"Dime todo lo que pasa por tu cabeza: qué miras, qué esperas, qué te confunde."

Nielsen lo llama el método #1 de usabilidad.

Qué revela

Dónde se confunden y por qué
Qué etiquetas no entienden
La brecha entre su modelo mental y tu diseño

 Cuidado: pensar en voz alta es **algo artificial** y puede ralentizar al usuario. Combínalo con datos de comportamiento.

Who · El quién

Los participantes y el equipo que conduce la prueba

Participantes: representar al usuario objetivo

El participante debe coincidir con tu usuario real

“ La regla de oro

Quienes **reclutas** deben ser los mismos que de verdad **usarían el producto**. Si no, descubrirás problemas que no existen e ignorarás los que sí.

Definidos por subgrupos

Por experiencia, familiaridad, habilidad, ocupación, conocimiento del dominio y demografía.

El dominio importa

En una app de finanzas, usuarios de distinto nivel de ingreso dan insights distintos. Deberías reclutar según tu objetivo real.

¿Cuántos usuarios? La regla de los 5

5

Con 5 usuarios detectas ~85% de los problemas


$$N.\text{º problemas} = N \cdot (1 - (1 - L)^n)$$

N = total de problemas · n = usuarios · $L \approx 31\%$ por usuario

+

Más usuarios = ver los mismos problemas otra vez

Problemas detectados según N° de usuarios



Es un método "de descuento" para testing **cualitativo**. Mejor 3 rondas de 5 que 1 de 15. Para significancia estadística: 20–40+.

Roles del equipo de testing

 Moderador

Guía al participante y lo sondea con preguntas.

 Note-taker

Captura los datos y observaciones de la sesión.

 Observador(es)

Del equipo de UX; miran sin intervenir.

 Técnico

Opera el sistema probado o el equipo de testing.

 El rol más delicado es el **moderador**: puede salvar o arruinar los datos.

El moderador: guía, no profesor

La regla más difícil: saber cuándo callarse



Haz

Deja claro: "probamos el producto, no a ti"

Observa en silencio mientras trabajan

Si se traban mucho: "¿qué estás pensando?"

Acepta los silencios incómodos



Evita

Ayudar o corregir apenas dudan

Explicar la interfaz ("eso es un link")

Reaccionar a sus aciertos o errores

Preguntas que sugieren la respuesta



Tu instinto será **rescatarlos**. Resiste: cada vez que se traban, descubres un problema real.

No contamines el dato

El moderador no debe influir en las decisiones ni acciones del usuario



Pregunta que guía ✕

"¿Qué tan fácil te resultó pagar?"

Asume que fue fácil. Sugiere la respuesta.



Pregunta neutral ✓

"Cuéntame cómo fue el proceso de pago para ti."

Abierta. No insinúa nada.



Los dos errores típicos: usar **términos de la propia interfaz** y dar **tips o explicaciones** innecesarias.

El buen moderador observa lo que no es obvio

No solo dónde hacen clic — todo el contexto cuenta

Mira más allá de la pantalla

En una app móvil, ¿cómo sostiene el celular?
¿Llega el pulgar al botón? ¿Cambia de mano?

El lenguaje corporal, las dudas y los suspiros dicen tanto como los clics.

Sintetiza, no solo transcribe

Conecta lo que ve entre participantes y
detecta el patrón detrás de los síntomas.

De "este usuario se perdió aquí" a "el menú no comunica su contenido".

3 técnicas de facilitación (NN/g)

Cómo profundizar sin meter ruido ni sesgo

Echo

Repites la última palabra del usuario con tono de pregunta.

- "Esto es raro..."
- "¿Raro?"

Boomerang

Devuelves su pregunta con otra neutral.

- "¿Esto qué hace?"
- "¿Qué esperarías que haga?"

Columbo

Empiezas una frase y la dejas en el aire para que la completen.

"Y entonces harías clic en..."



Las tres comparten una idea: **hablar lo mínimo** y dejar que el usuario llene el espacio.

El resultado: un plan de testing

El diseño del test se documenta en un test plan (o test protocol)

 Captura el Why · What · How · Who

Es el documento que reúne las cuatro dimensiones que acabamos de ver.



Checklists por rol

Qué hace cada miembro del equipo



Guion del moderador

Qué decir y en qué orden



Consentimiento informado

El participante acepta ser grabado



Acuerdo de confidencialidad (NDA)

Protege lo que se muestra

Medición de resultados

Tres familias de medidas que se complementan

Tres tipos de medidas



Performance

Lo que el usuario hace: éxito, tiempo, errores



Self-report

Lo que el usuario percibe: ratings y comentarios



Issue-based

Los problemas que el usuario encuentra



Performance = **cuantitativo**, self-report = mixto, issue-based = **cualitativo**. Juntas dan la imagen completa.

Métricas de performance

Cinco tipos básicos

- ✓ **Tasa de éxito**
Qué tan efectivamente completan la tarea (binaria o por niveles)
- ⌚ **Tiempo en tarea**
Cuánto tiempo requiere completarla
- ❗ **Errores**
Los errores cometidos durante la tarea
- 🔄 **Eficiencia**
El nivel de esfuerzo requerido
- 📈 **Aprendibilidad**
Cómo cambia el desempeño con el tiempo

💡 La **tasa de éxito** es la más simple y poderosa: si no logran la tarea, lo demás importa poco.

SUS · System Usability Scale

Self-report: le preguntamos al usuario por su percepción

✓ Qué es

Cuestionario de 10 ítems al final de la sesión;
alternan tono positivo y negativo.

📊 Puntaje

Se combina en un puntaje 0–100 (no es un %).
Ejemplo: total 22 → $22 \times 2.5 = 55$.



Para comparar versiones o como benchmark. >68 =
sobre el promedio.

	Strongly disagree					Strongly agree	
1. I think that I would like to use this system frequently.	☐	☐	☐	☐	☒		4
	1	2	3	4	5		
2. I found the system unnecessarily complex.	☐	☐	☐	☒	☐		1
	1	2	3	4	5		
3. I thought the system was easy to use.	☐	☒	☐	☐	☐		1
	1	2	3	4	5		
4. I think I would need the support of a technical person to be able to use this system.	☒	☐	☐	☐	☐		4
	1	2	3	4	5		
5. I found the various functions in this system were well integrated.	☐	☒	☐	☐	☐		1
	1	2	3	4	5		
6. I thought this system was too inconsistent.	☐	☐	☒	☐	☐		2
	1	2	3	4	5		
7. I would imagine that most people would learn to use this system very quickly.	☐	☒	☐	☐	☐		1
	1	2	3	4	5		
8. I found the system very cumbersome to use.	☐	☐	☐	☒	☐		1
	1	2	3	4	5		
9. I felt very confident using the system.	☐	☐	☐	☐	☒		4
	1	2	3	4	5		
10. I needed to learn a lot of things before I could get going with this system.	☐	☒	☐	☐	☐		3
	1	2	3	4	5		

Total = 22 **SUS Score = $22 \times 2.5 = 55$** 58

USE

Usefulness, Satisfaction & Ease of use — cuatro subescalas



Utilidad

¿Me ayuda a ser más efectivo y productivo?



Facilidad de uso

¿Es simple, flexible y sin esfuerzo?



Facilidad de aprendizaje

¿Aprendí a usarlo rápido?



Satisfacción

¿Lo recomendaría? ¿Es agradable de usar?

Usefulness

- It helps me be more effective.
- It helps me be more productive.
- It is useful.
- It gives me more control over the activities in my life.
- It makes the things I want to accomplish easier to get done.
- It saves me time when I use it.
- *It meets my needs.*
- It does everything I would expect it to do.

Ease of Use

- It is easy to use.
- It is simple to use.
- It is user friendly.
- It requires the fewest steps possible to accomplish what I want to do with it.
- *It is flexible.*
- *Using it is effortless.*
- *I can use it without written instructions.*
- *I don't notice any inconsistencies as I use it.*
- *Both occasional and regular users would like it.*
- *I can recover from mistakes quickly and easily.*
- *I can use it successfully every time.*

Ease of Learning

- I learned to use it quickly.
- I easily remember how to use it.
- It is easy to learn to use it.
- *I quickly became skillful with it.*

Satisfaction

- I am satisfied with it.
- I would recommend it to a friend.
- It is fun to use.
- It works the way I want it to work.
- It is wonderful.
- I feel I need to have it.
- It is pleasant to use.

Users rate agreement with these statements on a 7-point Likert scale, ranging from strongly disagree to strongly agree. Statements in *italics* were found to weight less heavily than the others.



Cada afirmación se responde en una **escala Likert de 7 puntos** (los ítems en cursiva pesan menos).

Escalas Likert

La base de SUS, USE y casi toda métrica de self-report

“ Qué es

Una escala numérica de **3, 5, 7, 9 u 11 puntos** con etiquetas descriptivas, donde el usuario marca su nivel de acuerdo.



Más puntos = más matiz, pero más difícil de responder.
5 y 7 son los más usados.

1

Muy en desacuerdo

2

En desacuerdo

3

Ni de acuerdo ni en desacuerdo

4

De acuerdo

5

Muy de acuerdo

Métricas issue-based

Un issue es un problema que el usuario encuentra al usar el sistema

Ejemplos de issues

Comportamientos que impiden completar la tarea

Decir que terminó cuando no es así

Elegir el link equivocado / malinterpretar contenido

No ver algo que debería notarse

¿Cómo los detectamos?

Acciones del usuario en la tarea.

Comportamiento: expresiones verbales (confusión, frustración) y no verbales (gestos, mirada).

Priorizar: severidad de los issues

No todo se arregla a la vez — se prioriza



La severidad depende de...

Impacto en la experiencia de usuario

Frecuencia con que ocurre

Impacto en los objetivos del negocio

Costo técnico de arreglarlo

Baja

Molesta, pero no causa que la tarea falle

Media

Dificulta mucho la tarea, pero no la hace fallar

Alta

Lleva directamente al fracaso de la tarea

IA en testing con usuarios

El gran tema de 2025 — y un debate abierto

Usuarios sintéticos

Personas generadas por IA (LLMs) que simulan a usuarios reales

“ Synthetic Users

Modelos de IA, entrenados sobre datos de interacción humana, que *simulan comportamiento y decisiones* al usar un producto — generando feedback en minutos en vez de semanas.



Rápido

Resultados en horas, no semanas



Barato

Sin reclutar ni pagar participantes



Escalable

100 'entrevistas' sin fatiga

Promesa vs límites



Para qué sirven

Detectar problemas obvios antes de testear con humanos

Generar hipótesis y afinar el guion del test

Auditar la lógica de una interfaz a bajo costo



Dónde fallan

Siguen rutas "limpias"; los humanos dudan y se pierden

No sienten frustración, confusión ni emoción reales

No muestran dónde las personas reales se traban



El modelo sano para 2025: "IA para velocidad, humanos para la verdad". La IA acota dónde mirar; las personas confirman qué es real.

¿Preguntas?

Clase 20 – Testing con Usuarios



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

IIC2182 – Primer Semestre 2026

¿Preguntas?

Clase 20 – Testing con Usuarios



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

IIC2182 – Primer Semestre 2026